

ĐẠI HỌC QUỐC GIA HÀ NỘI

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN



BÁO CÁO

**ĐỀ TÀI: ỨNG DỤNG HỌC MÁY
TRONG DỰ ĐOÁN UNG THƯ CỐ TỬ CUNG**

Giảng viên hướng dẫn: TS. Cao Văn Chung

Mã học phần: MAT3533

Môn học: Học máy

STT	Họ và tên	MSV	Lớp
1	Mẫn Thị Ngân An	23000088	K68A2
2	Nguyễn Thị Ngọc Hân	23000118	K68A2
3	Lại Thị Huế	23000122	K68A2

Hà Nội, ngày 15 tháng 06 năm 2026

BÁO CÁO

ĐỀ TÀI

ỨNG DỤNG HỌC MÁY

TRONG DỰ ĐOÁN UNG THƯ CỐ TỬ CUNG

Giảng viên hướng dẫn: TS. Cao Văn Chung

Mã học phần: MAT3533

Môn học: Học máy

THÀNH VIÊN NHÓM

STT	Họ và tên	MSSV	Lớp
1	Mẫn Thị Ngân An	23000088	K68A2
2	Nguyễn Thị Ngọc Hân	23000118	K68A2
3	Lại Thị Huế	23000122	K68A2

Mục lục

MỞ ĐẦU	3
1 TỔNG QUAN DỮ LIỆU VÀ TIỀN XỬ LÝ	4
1.1 Tổng quan về dữ liệu	4
1.2 Kiểm tra dữ liệu	4
1.3 Xử lý giá trị thiếu	5
1.3.1 Chuẩn hóa dữ liệu đầu vào	5
1.3.2 Loại bỏ thuộc tính không phù hợp	5
1.3.3 Điền giá trị thiếu	5
1.4 Tách biến đầu vào và đầu ra	6
1.5 Chia tập dữ liệu	6
1.6 Chuẩn hóa dữ liệu	6
1.7 Xử lý mất cân bằng dữ liệu bằng SMOTE	7
1.7.1 Nguồn gốc	7
1.7.2 Ý tưởng	7
1.7.3 Thuật toán chi tiết	7
1.7.4 Ưu điểm và Nhược điểm	8
2 GIẢM CHIỀU DỮ LIỆU VÀ XÂY DỰNG MÔ HÌNH	10
2.1 Phân tích thành phần chính (PCA)	10
2.1.1 Mục đích	10
2.1.2 Cơ sở lý thuyết	10
2.1.3 Các bước thực hiện	11
2.1.4 Nhận xét	12
2.2 Phân tích phân biệt tuyến tính (LDA)	13
2.2.1 Mục đích	13
2.2.2 Cơ sở lý thuyết	13
2.2.3 Trực quan hóa	14
2.3 Thuật toán K-Nearest Neighbors (KNN)	15
2.3.1 Giới thiệu	15
2.3.2 Cách một thuật toán KNN hoạt động	16
2.3.3 Hàm tính khoảng cách	16
2.3.4 Tìm K phần tử gần nhất và dự đoán đầu ra	16
2.3.5 Lưu ý khi chọn K bằng Grid Search	17
2.4 Hồi quy Logistic (Logistic Regression)	17
2.4.1 Mô hình hóa Xác suất	17
2.4.2 Hàm Sigmoid (Logistic)	18
2.4.3 Quyết định lớp dựa trên xác suất	18
2.4.4 Hàm mất mát (Loss Function)	18
2.4.5 Regularization trong Logistic Regression	18
2.4.6 Tối ưu hóa mô hình	20
2.4.7 Đặc điểm của mô hình	20

2.5	Support Vector Machine (SVM)	20
2.5.1	Giới thiệu	20
2.5.2	Siêu phẳng phân tách	20
2.5.3	Margin và bài toán tối ưu	21
2.5.4	Hard Margin và Soft Margin SVM	22
2.5.5	Kernel SVM	22
2.6	Thuật toán K-Means	24
2.6.1	Giới thiệu	24
2.6.2	Biểu diễn dữ liệu	24
2.6.3	Biến ẩn trong K-Means	24
2.6.4	Hàm mục tiêu của K-Means	25
2.6.5	Khoảng cách Euclidean	25
2.6.6	Quy tắc gán cụm	26
2.6.7	Cập nhật tâm cụm	26
2.6.8	Các bước thực hiện thuật toán K-Means	26
2.6.9	Lựa chọn số cụm K bằng Elbow Method và Silhouette Score	26
3	KẾT QUẢ THỰC NGHIỆM VÀ ĐÁNH GIÁ	28
3.1	Thiết lập thực nghiệm	28
3.2	Kết quả với tỷ lệ Train:Validation = 4:1	28
3.3	Kết quả với tỷ lệ Train:Validation = 7:3	30
3.4	Kết quả với tỷ lệ Train:Validation = 6:4	31
3.5	So sánh tổng hợp các mô hình trên tập Test cố định	33
3.6	Đánh giá hiện tượng overfitting	33
3.7	Đánh giá tác động của PCA và LDA	33
3.8	Đánh giá theo Confusion Matrix	34
3.9	Chuyển đổi bài toán phân loại sang bài toán hồi quy	35
3.10	Kết quả phân cụm K-Means	36
3.11	Kết luận phần thực nghiệm	37
	KẾT LUẬN	38
	TÀI LIỆU THAM KHẢO	39

MỞ ĐẦU

Ung thư cổ tử cung là một trong những bệnh lý nguy hiểm thường gặp ở phụ nữ và có thể gây ra hậu quả nghiêm trọng nếu không được phát hiện và điều trị kịp thời. Tuy nhiên, bệnh có khả năng được phòng ngừa và phát hiện sớm thông qua các phương pháp sàng lọc, xét nghiệm và phân tích các yếu tố nguy cơ liên quan. Trong thực tế, việc chẩn đoán ung thư cổ tử cung thường dựa trên các xét nghiệm y tế như Pap smear, HPV test hoặc sinh thiết. Mặc dù các phương pháp này có độ tin cậy cao, quá trình thực hiện có thể tốn thời gian, chi phí và phụ thuộc vào điều kiện cơ sở y tế.

Trong bối cảnh đó, việc khai thác dữ liệu bệnh nhân để hỗ trợ đánh giá nguy cơ mắc bệnh là một hướng tiếp cận có ý nghĩa thực tiễn. Các yếu tố như tuổi, tiền sử sinh sản, thói quen sinh hoạt, tình trạng hút thuốc, sử dụng biện pháp tránh thai, bệnh lây truyền qua đường tình dục và các kết quả xét nghiệm có thể cung cấp nhiều thông tin quan trọng cho quá trình dự đoán. Khi được xử lý và phân tích phù hợp, các dữ liệu này có thể hỗ trợ xây dựng mô hình dự đoán nhằm nhận diện sớm các trường hợp có nguy cơ cao.

Sự phát triển của học máy (*Machine Learning*) đã mở ra khả năng xây dựng các mô hình phân loại dựa trên dữ liệu. Thay vì chỉ dựa vào quan sát thủ công, các thuật toán học máy có thể học từ dữ liệu quá khứ, phát hiện mối quan hệ giữa các đặc trưng đầu vào và biến mục tiêu, từ đó đưa ra dự đoán cho các mẫu dữ liệu mới. Đặc biệt trong lĩnh vực y tế, các mô hình học máy có thể đóng vai trò như một công cụ hỗ trợ ra quyết định, giúp nâng cao hiệu quả sàng lọc ban đầu và giảm nguy cơ bỏ sót các trường hợp bệnh.

Trong đề tài này, nhóm sử dụng bộ dữ liệu *Cervical Cancer Risk Factors*, bao gồm các thông tin liên quan đến yếu tố nguy cơ ung thư cổ tử cung. Biến mục tiêu được lựa chọn là *Biopsy*, trong đó giá trị 0 biểu thị bệnh nhân không có dấu hiệu ung thư cổ tử cung và giá trị 1 biểu thị bệnh nhân có dấu hiệu ung thư cổ tử cung. Dữ liệu ban đầu tồn tại các vấn đề như giá trị thiếu, khác biệt thang đo giữa các thuộc tính và mất cân bằng lớp, do đó cần được tiền xử lý trước khi đưa vào mô hình.

Quy trình thực hiện đề tài bao gồm các bước chính: kiểm tra và làm sạch dữ liệu, xử lý giá trị thiếu, chuẩn hóa dữ liệu, chia tập huấn luyện và tập kiểm tra, xử lý mất cân bằng dữ liệu bằng SMOTE, giảm chiều dữ liệu bằng PCA và LDA, sau đó xây dựng và đánh giá các mô hình học máy. Các thuật toán được sử dụng trong báo cáo gồm K-Nearest Neighbors (KNN), Logistic Regression, Support Vector Machine (SVM) và K-Means. Trong đó, KNN, Logistic Regression và SVM được sử dụng cho bài toán phân loại, còn K-Means được dùng để phân tích cấu trúc cụm tiềm ẩn của dữ liệu.

Mục tiêu của đề tài là so sánh hiệu quả của các mô hình học máy trên nhiều không gian dữ liệu khác nhau, bao gồm dữ liệu gốc, dữ liệu sau khi giảm chiều bằng PCA và dữ liệu sau khi giảm chiều bằng LDA. Các mô hình được đánh giá thông qua các chỉ số như Accuracy, Precision, Recall, F1-score và Confusion Matrix. Do bài toán thuộc lĩnh vực y tế, chỉ số Recall được đặc biệt quan tâm vì việc bỏ sót bệnh nhân có nguy cơ mắc bệnh có thể gây ra hậu quả nghiêm trọng hơn so với việc dự đoán nhầm một số trường hợp không mắc bệnh.

Thông qua đề tài này, nhóm không chỉ vận dụng các kiến thức về tiền xử lý dữ liệu, giảm chiều và xây dựng mô hình học máy, mà còn phân tích được vai trò của từng kỹ thuật trong việc cải thiện chất lượng dự đoán. Kết quả thực nghiệm là cơ sở để đánh giá khả năng ứng dụng học máy trong hỗ trợ sàng lọc và phát hiện sớm nguy cơ ung thư cổ tử cung.

1 TỔNG QUAN DỮ LIỆU VÀ TIỀN XỬ LÝ

1.1 Tổng quan về dữ liệu

Bộ dữ liệu được sử dụng trong đề tài là *Cervical Cancer Risk Factors*, bao gồm các thông tin liên quan đến đặc điểm cá nhân, hành vi và tiền sử bệnh lý của bệnh nhân nhằm hỗ trợ dự đoán nguy cơ mắc ung thư cổ tử cung.

Dữ liệu gồm 858 mẫu và 36 thuộc tính, trong đó mỗi dòng tương ứng với một bệnh nhân, các cột biểu diễn các đặc trưng như:

- Tuổi (Age)
- Số bạn tình (Number of sexual partners)
- Tuổi quan hệ lần đầu (First sexual intercourse)
- Số lần mang thai (Num of pregnancies)
- Hút thuốc (Smokes, Smokes (years), Smokes (packs/year))
- Sử dụng biện pháp tránh thai (Hormonal Contraceptives, IUD)
- Các bệnh lây truyền qua đường tình dục (STDs)
- Các kết quả xét nghiệm (Hinselmann, Schiller, Citology, Biopsy)

Biến mục tiêu được lựa chọn trong bài toán là:


- **Biopsy**
 - 0 → Không mắc bệnh
 - 1 → Có dấu hiệu ung thư cổ tử cung

Việc lựa chọn biến Biopsy giúp bài toán tập trung vào mục tiêu chẩn đoán chính xác tình trạng bệnh lý của bệnh nhân dựa trên các đặc trưng đầu vào.

1.2 Kiểm tra dữ liệu

Trước khi tiến hành xây dựng mô hình, việc kiểm tra dữ liệu là bước quan trọng nhằm hiểu rõ cấu trúc, kiểu dữ liệu và các vấn đề tiềm ẩn.

Kết quả khảo sát ban đầu cho thấy dữ liệu tồn tại nhiều giá trị thiếu, đặc biệt ở các thuộc tính liên quan đến bệnh lây truyền qua đường tình dục (STDs). Một số thuộc tính có tỷ lệ thiếu rất cao, ảnh hưởng đáng kể đến chất lượng dữ liệu.



Hình 1: Số lượng giá trị thiếu của các thuộc tính trước tiền xử lý

Ngoài ra, các giá trị thiếu ban đầu được biểu diễn dưới dạng ký tự “?” thay vì giá trị chuẩn NaN, do đó cần được xử lý trước khi thực hiện các bước tiếp theo.

1.3 Xử lý giá trị thiếu

1.3.1 Chuẩn hóa dữ liệu đầu vào

Trước tiên, các giá trị không hợp lệ (“?”) được chuyển đổi về dạng giá trị thiếu chuẩn. Sau đó, toàn bộ dữ liệu được chuyển sang dạng số để đảm bảo tương thích với các thuật toán học máy.

Việc chuẩn hóa định dạng dữ liệu giúp quá trình xử lý và huấn luyện mô hình diễn ra ổn định hơn.

1.3.2 Loại bỏ thuộc tính không phù hợp

Một số thuộc tính có tỷ lệ giá trị thiếu quá lớn (trên 90%), cụ thể:

- STDs: Time since first diagnosis
- STDs: Time since last diagnosis

Các thuộc tính này không cung cấp đủ thông tin hữu ích nên được loại bỏ khỏi tập dữ liệu. Việc loại bỏ giúp giảm nhiễu và tránh ảnh hưởng tiêu cực đến quá trình học của mô hình.

1.3.3 Điền giá trị thiếu

Sau khi loại bỏ các thuộc tính có tỷ lệ thiếu quá cao, nhóm tiến hành thống kê các đại lượng như Mean, Median, Mode và độ lệch phân phối để lựa chọn phương án điền khuyết phù hợp. Kết quả khảo sát cho thấy nhiều thuộc tính trong bộ dữ liệu có phân phối lệch mạnh, đồng thời một số biến nhị phân có giá trị Median trùng với Mode.

Vì vậy, trong thực nghiệm cuối cùng, nhóm sử dụng Median làm chiến lược điền khuyết thống nhất cho các cột còn lại. Việc sử dụng Median giúp hạn chế ảnh hưởng của các giá trị ngoại lai so với Mean, đồng thời vẫn phù hợp với nhiều biến nhị phân/phân loại mã hóa số trong bộ dữ liệu do Median thường trùng với giá trị xuất hiện phổ biến nhất.

Cách xử lý này giúp dữ liệu sau tiền xử lý đầy đủ hơn, đồng thời đảm bảo tính ổn định cho các mô hình học máy trong quá trình huấn luyện.

Bảng 1: Thống kê và chiến lược xử lý dữ liệu thiếu

Thuộc tính	Thiếu (%)	Mean	Median	Mode	Skewness	Xử lý
IUD (years)	13.64	0.51	0	0	5.00	Median
Hormonal Contraceptives (y)	12.59	2.25	0.50	0	2.63	Median
Number of sexual partners	3.03	2.52	2	2	5.45	Median
Smokes	1.52	0.14	0	0	2.01	Mode/Median

Trong thực nghiệm này, do đa số các biến số đều thể hiện độ lệch mạnh, nhóm ưu tiên sử dụng *Median* làm phương pháp chủ đạo để đảm bảo tính ổn định của mô hình.

1.4 Tách biến đầu vào và đầu ra

Sau khi hoàn tất quá trình làm sạch dữ liệu, tập dữ liệu được chia thành:

- X : tập đặc trưng đầu vào
- y : biến mục tiêu Biopsy

Việc tách riêng biến đầu vào và đầu ra là bước cần thiết để phục vụ cho quá trình huấn luyện và đánh giá mô hình học máy.

1.5 Chia tập dữ liệu

Dữ liệu được xử lý theo quy trình hai bước nhằm đảm bảo tính khách quan và hiệu quả cho mô hình:

- **Bước 1:** Tách riêng 20% dữ liệu làm tập Test cố định để đánh giá khách quan mô hình cuối cùng.
- **Bước 2:** Phần dữ liệu còn lại được chia thành tập Train và Validation theo ba tỷ lệ khác nhau: 4:1, 7:3 và 6:4.

Việc chia dữ liệu được thực hiện theo phương pháp phân tầng (stratified splitting) nhằm duy trì tính nhất quán và bảo toàn tỷ lệ phân bố giữa hai lớp trong tập dữ liệu.

Điều này đặc biệt quan trọng đối với các bài toán có dữ liệu mất cân bằng.

1.6 Chuẩn hóa dữ liệu

Để đảm bảo các đặc trưng có cùng thang đo, dữ liệu được chuẩn hóa theo công thức:


$$x_{scaled} = \frac{x - \mu}{\sigma} \quad (1)$$

Trong đó:

- x : giá trị ban đầu
- μ : giá trị trung bình
- σ : độ lệch chuẩn

Việc chuẩn hóa giúp các thuật toán dựa trên khoảng cách như KNN hoạt động hiệu quả hơn, đồng thời cải thiện tốc độ hội tụ của các mô hình học máy.

1.7 Xử lý mất cân bằng dữ liệu bằng SMOTE



Hình 2: Phân bố dữ liệu của biến mục tiêu Biopsy

Phân tích dữ liệu cho thấy sự mất cân bằng rõ rệt giữa hai lớp của biến mục tiêu. Số lượng mẫu không mắc bệnh lớn hơn nhiều so với số mẫu mắc bệnh.

Để khắc phục vấn đề này, phương pháp SMOTE (Synthetic Minority Over-sampling Technique) được áp dụng nhằm tạo thêm các mẫu dữ liệu tổng hợp cho lớp thiểu số.

1.7.1 Nguồn gốc

Thuật toán SMOTE (Synthetic Minority Over-sampling Technique) được đề xuất lần đầu tiên vào năm 2002 bởi **Nitesh V. Chawla** và các cộng sự trong bài báo khoa học mang tên "*SMOTE: Synthetic Minority Over-sampling Technique*".

Mục tiêu cốt lõi của bài báo là giải quyết nhược điểm của phương pháp *Random Oversampling* (nhân bản ngẫu nhiên các mẫu thiểu số). Random Oversampling tuy cân bằng được dữ liệu nhưng lại dễ dẫn đến hiện tượng **Overfitting** (mô hình học thuộc lòng các mẫu bị trùng lặp thay vì học được đặc trưng tổng quát).

1.7.2 Ý tưởng

Thay vì sao chép nguyên xi các mẫu cũ, SMOTE tạo ra các mẫu dữ liệu **tổng hợp (synthetic)** hoàn toàn mới. Thuật toán này hoạt động trong “không gian đặc trưng” (feature space) chứ không phải không gian dữ liệu gốc.

Nó tạo ra các điểm dữ liệu mới bằng cách **nội suy tuyến tính** (linear interpolation) giữa một điểm dữ liệu thuộc nhóm thiểu số (minority class) và các “láng giềng gần nhất” (nearest neighbors) của nó cũng thuộc nhóm thiểu số đó.

1.7.3 Thuật toán chi tiết

Theo lý thuyết gốc, quá trình tạo ra một mẫu dữ liệu nhân tạo bằng SMOTE diễn ra theo các bước sau:

- Bước 1:** Xét một mẫu dữ liệu x_i bất kỳ thuộc nhóm thiểu số (minority class).
- Bước 2:** Sử dụng thuật toán k -Nearest Neighbors (KNN) để tìm ra k láng giềng gần nhất của x_i (các láng giềng này cũng phải thuộc nhóm thiểu số). Trong bài báo gốc, tác giả thường mặc định sử dụng $k = 5$.

3. **Bước 3:** Tùy thuộc vào tỷ lệ oversampling mong muốn, thuật toán sẽ chọn ngẫu nhiên một (hoặc nhiều) láng giềng trong số k láng giềng vừa tìm được. Gọi láng giềng được chọn là $x_{neighbor}$.
4. **Bước 4:** Tạo ra mẫu dữ liệu tổng hợp mới x_{new} nằm trên đoạn thẳng nối giữa x_i và $x_{neighbor}$ trong không gian đặc trưng theo công thức:

$$x_{new} = x_i + \lambda \times (x_{neighbor} - x_i) \quad (2)$$

Trong đó:

- x_i : Mẫu dữ liệu thiếu số ban đầu (đang xét).
- $x_{neighbor}$: Mẫu láng giềng được chọn ngẫu nhiên.
- λ : Một số thực ngẫu nhiên trong đoạn $[0, 1]$.
- x_{new} : Điểm dữ liệu tổng hợp mới được sinh ra.


1.7.4 Ưu điểm và Nhược điểm

Ưu điểm:

- **Giảm thiểu Overfitting:** Vì nó tạo ra các điểm dữ liệu mới thay vì chỉ nhân bản, mô hình học được ranh giới quyết định (decision boundaries) tổng quát hơn.
- **Không mất mát thông tin:** Giữ nguyên toàn bộ thông tin của tập dữ liệu ban đầu thay vì cắt bỏ như Undersampling.

Nhược điểm:

- **Có thể tạo ra nhiễu (Noise):** SMOTE gốc không quan tâm đến nhóm đa số. Nếu x_i nằm quá sát ranh giới, việc nội suy có thể tạo ra điểm mới nằm lẫn sâu vào vùng của nhóm đa số.
- **Hạn chế với dữ liệu cao chiều:** Không hiệu quả với dữ liệu phân loại cao chiều (High-dimensional) hoặc dữ liệu rải rác (Sparse data).



Hình 3: Các bước thực hiện SMOTE

Sau khi áp dụng SMOTE, tập dữ liệu huấn luyện đạt trạng thái cân bằng, giúp mô hình học tốt hơn và giảm hiện tượng thiên lệch về lớp chiếm đa số.

2 GIẢM CHIỀU DỮ LIỆU VÀ XÂY DỰNG MÔ HÌNH

2.1 Phân tích thành phần chính (PCA)

2.1.1 Mục đích

Phân tích thành phần chính (Principal Component Analysis – PCA) là một phương pháp giảm chiều dữ liệu không giám sát, nhằm biến đổi dữ liệu ban đầu sang một không gian mới có số chiều thấp hơn nhưng vẫn giữ được phần lớn thông tin quan trọng.

Trong bộ dữ liệu *Cervical Cancer Risk Factors*, số lượng thuộc tính sau khi làm sạch vẫn còn tương đối lớn và tồn tại sự tương quan giữa các biến. Điều này có thể gây ra hiện tượng dư thừa thông tin và làm giảm hiệu quả của mô hình học máy.

Do đó, việc áp dụng PCA mang lại nhiều lợi ích:

- Giảm số chiều dữ liệu, giúp đơn giản hóa bài toán
- Loại bỏ sự tương quan giữa các biến
- Giảm nhiễu và cải thiện chất lượng dữ liệu
- Tăng tốc độ huấn luyện mô hình
- Hỗ trợ trực quan hóa dữ liệu trong không gian thấp chiều

2.1.2 Cơ sở lý thuyết

Giả sử dữ liệu ban đầu gồm N mẫu, mỗi mẫu có d đặc trưng. PCA thực hiện các bước chính như sau:

1. Tính vector kỳ vọng trên toàn bộ dữ liệu:

$$\bar{x} = \frac{1}{N} \sum_{n=1}^N x_n \quad (3)$$

Trong đó N là số lượng mẫu, và x_n là vector dữ liệu thứ n .

2. Chuẩn hóa dữ liệu:

$$\hat{x}_n = x_n - \bar{x}; \quad n = 1, 2, \dots, N. \quad (4)$$

3. Tính ma trận hiệp phương sai:

$$S = \frac{1}{N} \hat{X}^T \hat{X} \quad (5)$$

Trong đó $\hat{X}$ là ma trận dữ liệu đã được chuẩn hóa.

4. Tính các trị riêng λ_i và vector riêng u_i của ma trận hiệp phương sai.

$$S u_i = \lambda_i u_i$$

5. Chọn k giá trị riêng lớn nhất và k vector riêng tương ứng để xây dựng ma trận U_k

Tập hợp các vector này được dùng để tạo thành không gian con mới có số chiều nhỏ hơn.

6. Chiều dữ liệu sang không gian mới:


$$Z = \hat{X}U_k \quad (6)$$

Mã trận Z chứa các biểu diễn nén của dữ liệu trên không gian có số chiều thấp hơn.

Dữ liệu ban đầu có thể được xấp xỉ lại từ dữ liệu nén như sau:

$$\mathbf{x} \approx \mathbf{U}_k \mathbf{Z} + \bar{\mathbf{x}}$$


Trong đó $\mathbf{U}_k \mathbf{Z}$ là phần thông tin giữ lại và $\bar{\mathbf{x}}$ là trung bình của dữ liệu ban đầu được cộng lại để khôi phục vị trí gốc của dữ liệu.



2.1.3 Các bước thực hiện


Trong đề tài, PCA được áp dụng với mục tiêu giữ lại 95% phương sai của dữ liệu. Điều này đảm bảo rằng phần lớn thông tin quan trọng vẫn được bảo toàn sau khi giảm chiều.

Kết quả thực nghiệm cho thấy số chiều dữ liệu được giảm xuống còn 18 -19 chiều tùy theo tỷ lệ chia dữ liệu, trong khi vẫn giữ lại trên 95% phương sai., giúp giảm đáng kể độ phức tạp của bài toán mà không làm mất đi thông tin quan trọng.



Hình 4: Biểu đồ phương sai tích lũy của PCA

2.1.4 Nhận xét



Hình 5: Trực quan hóa dữ liệu sau khi giảm chiều bằng PCA

Kết quả trực quan hóa cho thấy dữ liệu sau khi giảm chiều bằng PCA đã bắt đầu hình thành các cụm nhất định. Tuy nhiên, ranh giới giữa hai lớp vẫn chưa rõ ràng.

- Nhóm không mắc bệnh có xu hướng tập trung tại một khu vực nhất định
- Nhóm mắc bệnh phân bố rộng hơn trong không gian đặc trưng
- Tồn tại sự chồng lấn giữa hai lớp, đặc biệt ở vùng trung tâm

Điều này cho thấy PCA giúp giảm chiều hiệu quả nhưng chưa tối ưu cho bài toán phân loại.

2.2 Phân tích phân biệt tuyến tính (LDA)

2.2.1 Mục đích

Linear Discriminant Analysis (LDA) là phương pháp giảm chiều có giám sát, nhằm tìm ra không gian đặc trưng mới giúp tối đa hóa khả năng phân tách giữa các lớp dữ liệu.

Cụ thể, LDA hướng tới:

- Tăng khoảng cách giữa các lớp
- Giảm độ phân tán trong cùng một lớp

Do sử dụng thông tin nhãn, LDA thường mang lại hiệu quả tốt hơn PCA trong các bài toán phân loại.

2.2.2 Cơ sở lý thuyết


Giả thiết Ta xét bài toán phân loại nhị phân (binary classification) với hai nhãn: $\{1, 2\}$. Đặt:

- X_1 : Tập dữ liệu có nhãn 1
- X_2 : Tập dữ liệu có nhãn 2

Giả sử khi chiếu dữ liệu xuống một chiều bất kỳ, ta có:

- Kỳ vọng (mean): m_1, m_2
- Phương sai (variance): s_1^2, s_2^2

Phân tích độ phân biệt trong các trường hợp của (m_1, m_2) và (s_1^2, s_2^2) như trong hình minh họa sau.



Hình 6: Ví dụ

Ta xét ba trường hợp minh họa bằng đồ thị:

- (A): $|m_1 - m_2|$ lớn nhưng s_1, s_2 cũng lớn $\rightarrow$ dữ liệu phân tán mạnh $\rightarrow$ vùng chồng lấn lớn $\rightarrow$ **độ phân biệt thấp**.
- (B): s_1, s_2 nhỏ nhưng $|m_1 - m_2|$ cũng nhỏ $\rightarrow$ dữ liệu gần nhau $\rightarrow$ vùng chồng lấn lớn $\rightarrow$ **độ phân biệt thấp**.
- (C): s_1, s_2 nhỏ và $|m_1 - m_2|$ lớn $\rightarrow$ vùng chồng lấn ít $\rightarrow$ **độ phân biệt cao**.

Từ các trường hợp trên, ta rút ra:

- **Phương sai trong lớp** (within-class variances): $N_j s_j^2$ với $N_j = |X_j|$ là số mẫu trong lớp X_j . Nếu nhỏ $\rightarrow$ dữ liệu tập trung $\rightarrow$ dễ phân biệt.
- **Phương sai giữa lớp** (between-class variance): $|m_1 - m_2|^2$. Nếu lớn $\rightarrow$ hai lớp phân bố xa nhau $\rightarrow$ dễ phân biệt.

Dữ liệu sẽ có khả năng phân biệt cao nếu:

- **Within-class variance nhỏ**: dữ liệu trong từng lớp ít phân tán.
- **Between-class variance lớn**: khoảng cách giữa các lớp lớn.

Để thực hiện phân tích Linear Discriminant Analysis (LDA), chúng ta làm theo các bước sau:

Bước 1: Tính S_W và S_B

Trong bước này, ta tính phương sai trong lớp (within-class variance) S_W và phương sai giữa các lớp (between-class variance) S_B .

- **Phương sai trong lớp (within-class variance):**

$$S_W = \sum_{x_n \in C_1} (x_n - m_1)(x_n - m_1)^T + \sum_{x_n \in C_2} (x_n - m_2)(x_n - m_2)^T \quad (7)$$

S_W thể hiện sự phân tán trong mỗi lớp, tức là sự biến động của các điểm trong lớp so với kỳ vọng của lớp đó.

- **Phương sai giữa các lớp (between-class variance):**

$$S_B = (m_1 - m_2)(m_1 - m_2)^T \quad (8)$$

S_B thể hiện sự phân tán giữa các lớp, tức là khoảng cách giữa các kỳ vọng m_1 và m_2 của hai lớp.

Bước 2: Tính $A = S_W^{-1} S_B$

$$A = S_W^{-1} S_B \quad (9)$$

Ma trận A này sẽ giúp ta tìm ra vector phân biệt tối ưu trong không gian dữ liệu.

Bước 3: Tính $L = \max\{\lambda_i\}$, $i = 1, 2, \dots, d$

$$L = \max\{\lambda_1, \lambda_2, \dots, \lambda_d\} \quad (10)$$

Chú ý: Với mỗi giá trị riêng λ , sẽ có vô số vector riêng tương ứng.

Bước 4: Chọn w

Sau khi có giá trị riêng lớn nhất, ta chọn vector phân biệt w sao cho:

$$(m_1 - m_2)^T w = L \quad (11)$$

Vector w được tính như sau:


$$w = S_W^{-1} (m_1 - m_2) \cdot \beta \quad (\beta > 0) \quad (12)$$

Trong đó β là hệ số điều chỉnh, giúp tối ưu hóa sự phân biệt giữa các lớp.

2.2.3 Trực quan hóa

Trong đề tài, do biến mục tiêu chỉ có hai lớp, LDA được sử dụng để giảm dữ liệu xuống một chiều duy nhất.

Việc giảm về 1 chiều giúp tối đa hóa khả năng phân tách giữa hai lớp, đồng thời giúp trực quan hóa dữ liệu một cách rõ ràng hơn.



Hình 7: Phân bố dữ liệu sau khi giảm chiều bằng LDA


Kết quả cho thấy dữ liệu sau khi áp dụng LDA đã được phân tách rõ ràng hơn so với PCA. Hai lớp dữ liệu có xu hướng tách biệt tốt trên trục đặc trưng mới.

Mặc dù vẫn tồn tại một vùng chồng lấn nhỏ, nhưng mức độ phân tách đã được cải thiện đáng kể, tạo điều kiện thuận lợi cho các mô hình phân loại hoạt động hiệu quả hơn.

2.3 Thuật toán K-Nearest Neighbors (KNN)

2.3.1 Giới thiệu

K-nearest neighbor là một trong những thuật toán supervised-learning đơn giản nhất trong Machine Learning. Khi training, thuật toán này không học một điều gì từ dữ liệu huấn luyện, mọi tính toán được thực hiện khi nó cần dự đoán kết quả của dữ liệu mới. K-nearest neighbor có thể áp dụng được vào cả hai loại của bài toán Supervised learning là Classification và Regression.



Hình 8: Ví dụ

2.3.2 Cách một thuật toán KNN hoạt động

Trong bài toán phân loại nhị phân, đầu ra y thuộc một trong hai loại: 0 hoặc 1. Các bước thực hiện của phương pháp K-NN được mô tả như sau:

1. Với mỗi điểm x (chưa biết nhãn) trong tập Validation.
2. Tính khoảng cách d_i từ x đến từng điểm x_i trong tập Training $\Rightarrow$ lập thành một mảng các khoảng cách.
3. Sắp xếp các khoảng cách này theo thứ tự tăng dần, đồng thời giữ lại chỉ số ban đầu của các phần tử d_i .
4. Tìm K chỉ số tương ứng với K phần tử x_i trong tập Training có khoảng cách d_i nhỏ nhất.
5. Tính nhãn dự đoán y_{pred} như sau:

$$y_{pred} = \begin{cases} 1, & \text{nếu } \frac{1}{K} \sum_{i=1}^K y_i \geq 0.5 \\ 0, & \text{nếu } \frac{1}{K} \sum_{i=1}^K y_i < 0.5 \end{cases} \quad (13)$$

Giải thích bước (v): Do y chỉ nhận giá trị 0 hoặc 1, nên $\frac{1}{K} \sum_{i=1}^K y_i$ chính là tỉ lệ xuất hiện của nhãn 1 trong số K láng giềng gần nhất. Nếu tỉ lệ này lớn hơn hoặc bằng 0.5, ta dự đoán $y_{pred} = 1$; ngược lại, nếu nhỏ hơn 0.5, ta dự đoán $y_{pred} = 0$.

Ta sẽ sử dụng lại các phương thức tính khoảng cách và tìm K mẫu gần nhất như sau:

2.3.3 Hàm tính khoảng cách

Trường hợp $d = 1$ (dữ liệu một chiều):

Khoảng cách giữa điểm cần dự đoán x và từng điểm huấn luyện x_i được tính theo công thức:

$$d_i = |x - x_i| \quad (14)$$

Trường hợp $d > 1$ (dữ liệu nhiều chiều):

Khi dữ liệu là vector nhiều chiều, khoảng cách giữa x và x_i được tính bằng công thức chuẩn Euclid (L2 norm):

$$d_i = \|x - x_i\|_2 = \sqrt{\sum_{j=1}^d (x_j - x_{i,j})^2} \quad (15)$$

Trong đó:

- $x = (x_1, x_2, \dots, x_d)$ là điểm cần dự đoán
- $x_i = (x_{i,1}, x_{i,2}, \dots, x_{i,d})$ là một điểm trong tập huấn luyện
- d là số chiều của dữ liệu

2.3.4 Tìm K phần tử gần nhất và dự đoán đầu ra

Sau khi tính được mảng các khoảng cách từ điểm cần dự đoán x đến các điểm trong tập huấn luyện, ta thu được một mảng khoảng cách:

$$D = (d_1, d_2, \dots, d_n) \quad (16)$$

Trong đó $d_i = \|x - x_i\|$ là khoảng cách từ điểm x đến mẫu huấn luyện x_i .

Ta sắp xếp các khoảng cách này theo thứ tự tăng dần và lấy chỉ số của K phần tử nhỏ nhất. Tập này tương ứng với K mẫu gần nhất với x trong tập huấn luyện.

Dự đoán đầu ra y cho điểm x được tính bằng cách lấy trung bình các nhãn của K láng giềng gần nhất:

$$\hat{y} = \frac{1}{K} \sum_{i=1}^K y_i \quad (17)$$

Và đầu ra cuối cùng được xác định theo quy tắc:

$$\hat{y} = \begin{cases} 1, & \text{nếu } \frac{1}{K} \sum_{i=1}^K y_i \geq 0.5 \\ 0, & \text{nếu } \frac{1}{K} \sum_{i=1}^K y_i < 0.5 \end{cases} \quad (18)$$

2.3.5 Lưu ý khi chọn K bằng Grid Search

Trong thuật toán K-Nearest Neighbors, việc lựa chọn tham số K ảnh hưởng trực tiếp đến hiệu quả phân loại của mô hình.

- Nếu K quá nhỏ, mô hình dễ bị ảnh hưởng bởi nhiễu và dẫn đến hiện tượng overfitting.
- Nếu K quá lớn, mô hình trở nên quá tổng quát và có thể bỏ sót các đặc trưng quan trọng của lớp thiểu số.

Để lựa chọn giá trị K phù hợp, nhóm sử dụng phương pháp Grid Search kết hợp Cross Validation.

Quá trình thực hiện gồm các bước:

1. Xây dựng tập giá trị ứng viên cho tham số K (K lẻ)
2. Với mỗi giá trị K , mô hình được đánh giá bằng phương pháp Cross Validation 5-fold trên tập huấn luyện.
3. Chỉ số đánh giá được lựa chọn là Recall nhằm ưu tiên khả năng phát hiện bệnh nhân mắc ung thư cổ tử cung.
4. Giá trị K cho kết quả tốt nhất được chọn làm tham số tối ưu cho mô hình.

2.4 Hồi quy Logistic (Logistic Regression)

Hồi quy logistic là một thuật toán học máy có giám sát được sử dụng phổ biến cho các bài toán phân loại nhị phân (binary classification). Mục tiêu của bài toán này là dự đoán một biến đầu ra y chỉ nhận một trong hai giá trị rời rạc, thường được mã hóa là 0 và 1. Tức là, $y \in \{0, 1\}$. Mặc dù tên của phương pháp chứa thuật ngữ "Hồi quy" (Regression), vốn thường liên quan đến việc dự đoán các giá trị liên tục, hồi quy logistic thực chất là một mô hình phân lớp (classification). Tên gọi này xuất phát từ việc mô hình cơ bản của nó tương tự như hồi quy tuyến tính, nhưng kết quả đầu ra được biến đổi để phù hợp với bài toán phân loại.

2.4.1 Mô hình hóa Xác suất

Không giống như một số thuật toán phân loại khác chỉ đưa ra dự đoán lớp, hồi quy logistic mô hình hóa xác suất có điều kiện (conditional probability) của một điểm dữ liệu thuộc về lớp dương (thường là lớp 1). Cụ thể, mô hình ước lượng xác suất $P(y = 1|x; \theta)$, trong đó:

- x là vector các đặc trưng đầu vào ($x \in \mathbb{R}^{n+1}$, với $x_0 = 1$ là hệ số chặn).
- θ là vector các tham số (trọng số) của mô hình ($\theta \in \mathbb{R}^{n+1}$).

Giá trị đầu ra của mô hình, ký hiệu là $h_\theta(x)$, biểu diễn xác suất này:

$$h_\theta(x) = P(y = 1|x; \theta) \quad (19)$$

2.4.2 Hàm Sigmoid (Logistic)

Để đảm bảo rằng giá trị đầu ra $h_\theta(x)$ nằm trong khoảng $(0, 1)$, hồi quy logistic sử dụng hàm sigmoid (còn gọi là hàm logistic) để biến đổi tổ hợp tuyến tính của các đặc trưng và tham số ($\theta^T x$). Hàm sigmoid được định nghĩa là:

$$g(z) = \frac{1}{1 + e^{-z}} \quad (20)$$

Hàm này nhận đầu vào là một số thực bất kỳ ($z \in \mathbb{R}$) và trả về một giá trị trong khoảng $(0, 1)$. Do đó, giả thuyết (hypothesis) của mô hình hồi quy logistic được viết là:

$$h_\theta(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}} \quad (21)$$

2.4.3 Quyết định lớp dựa trên xác suất

Sau khi tính được xác suất $h_\theta(x)$, ta chuyển đổi nó thành dự đoán lớp cụ thể bằng quy tắc ngưỡng (thường là 0.5):

$$\hat{y} = \begin{cases} 1, & \text{nếu } h_\theta(x) \geq 0.5 \\ 0, & \text{nếu } h_\theta(x) < 0.5 \end{cases} \quad (22)$$

Điều này tương đương với việc kiểm tra $\theta^T x \geq 0$, vì hàm sigmoid $g(z) \geq 0.5$ khi và chỉ khi $z \geq 0$.

2.4.4 Hàm mất mát (Loss Function)

Để huấn luyện mô hình, ta cần một hàm mất mát đánh giá sai lệch giữa dự đoán và giá trị thực. Hồi quy logistic sử dụng Log Loss (hay Binary Cross-Entropy):

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \log(h_\theta(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_\theta(x^{(i)})) \right] \quad (23)$$

trong đó:

- m : số lượng mẫu huấn luyện.
- $y^{(i)}$: nhãn thực tế của mẫu thứ i .
- $h_\theta(x^{(i)})$: xác suất dự đoán cho mẫu thứ i .

Hàm mất mát này khuyến khích mô hình dự đoán xác suất gần 1 cho các mẫu có $y = 1$ và gần 0 cho các mẫu có $y = 0$.

2.4.5 Regularization trong Logistic Regression

Trong quá trình huấn luyện mô hình Logistic Regression, nếu mô hình có quá nhiều đặc trưng hoặc các trọng số của mô hình có giá trị quá lớn, mô hình có thể học quá sát dữ liệu huấn luyện. Hiện tượng này gọi là *overfitting*, tức là mô hình đạt kết quả tốt trên tập huấn luyện nhưng dự đoán kém trên dữ liệu mới.

Để hạn chế hiện tượng overfitting, Logistic Regression thường được kết hợp với kỹ thuật *Regularization*. Ý tưởng chính của Regularization là thêm một thành phần phạt vào hàm mất mát nhằm kiểm soát độ lớn của các tham số mô hình. Khi đó, mô hình không chỉ tối thiểu hóa sai số dự đoán mà còn phải giữ cho các trọng số không quá lớn.

Hàm mất mát ban đầu của Logistic Regression là:

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)})) \right]$$

Khi thêm Regularization, hàm mất mát được viết lại dưới dạng:

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)})) \right] + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

Trong đó:

- m là số lượng mẫu huấn luyện.
- n là số lượng đặc trưng.
- θ_j là trọng số của đặc trưng thứ j .
- λ là hệ số điều chuẩn, dùng để kiểm soát mức độ phạt.
- $\frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$ là thành phần phạt Regularization.

Lưu ý rằng hệ số chặn θ_0 thường không bị phạt, do đó tổng phạt bắt đầu từ $j = 1$.

Trong Logistic Regression, dạng Regularization phổ biến nhất là **L2 Regularization**, còn gọi là **Ridge penalty**. Kỹ thuật này phạt tổng bình phương các trọng số, giúp các trọng số nhỏ lại nhưng thường không đưa chúng về đúng bằng 0. Nhờ đó, mô hình trở nên ổn định hơn và giảm nguy cơ phụ thuộc quá mức vào một vài đặc trưng cụ thể.

Ngoài L2 Regularization, còn có **L1 Regularization**, trong đó thành phần phạt có dạng:

$$\lambda \sum_{j=1}^n |\theta_j|$$

L1 Regularization có xu hướng làm một số trọng số trở về đúng bằng 0, từ đó có thể hỗ trợ lựa chọn đặc trưng. Tuy nhiên, trong thực nghiệm của đề tài, Logistic Regression được sử dụng chủ yếu với Regularization để tăng khả năng tổng quát hóa và hạn chế overfitting.

Tham số λ có ảnh hưởng quan trọng đến mô hình:

- Nếu λ quá nhỏ, mức phạt yếu, mô hình vẫn có thể bị overfitting.
- Nếu λ quá lớn, trọng số bị ép quá nhỏ, mô hình có thể trở nên quá đơn giản và dẫn đến underfitting.
- Nếu λ phù hợp, mô hình đạt được sự cân bằng giữa khả năng học từ dữ liệu và khả năng tổng quát hóa trên dữ liệu mới.

Trong thư viện `scikit-learn`, Logistic Regression thường sử dụng tham số C , trong đó:

$$C = \frac{1}{\lambda}$$

Do đó:

- C lớn tương ứng với Regularization yếu.
- C nhỏ tương ứng với Regularization mạnh.

Trong bài toán dự đoán ung thư cổ tử cung, việc sử dụng Regularization là cần thiết vì dữ liệu có nhiều đặc trưng

liên quan đến tiền sử bệnh lý, hành vi và xét nghiệm. Nếu không kiểm soát trọng số, mô hình có thể học quá mức các đặc trưng nhiễu hoặc các mẫu đặc biệt trong tập huấn luyện. Regularization giúp Logistic Regression ổn định hơn, cải thiện khả năng dự đoán trên tập kiểm tra và hỗ trợ mô hình hoạt động tốt hơn trong bài toán y tế.

2.4.6 Tối ưu hóa mô hình

Mục tiêu là tìm θ sao cho $J(\theta)$ nhỏ nhất. Phương pháp phổ biến là Gradient Descent:

$$\theta := \theta - \alpha \nabla J(\theta) \quad (24)$$

với α là tốc độ học (learning rate). Gradient của hàm mất mát được tính như sau:

$$\frac{\partial J(\theta)}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m \left(h_{\theta}(x^{(i)}) - y^{(i)} \right) x_j^{(i)} \quad (25)$$

2.4.7 Đặc điểm của mô hình

Hồi quy logistic là một mô hình phân biệt (discriminative model), học trực tiếp $P(y|x)$ mà không cần mô hình hóa $P(x|y)$. Một số đặc điểm nổi bật:

- Dễ diễn giải: Trọng số θ cho biết mức độ ảnh hưởng của từng đặc trưng.
- Hiệu quả: Phù hợp với dữ liệu phân biệt tuyến tính và dễ tính toán.

2.5 Support Vector Machine (SVM)

2.5.1 Giới thiệu

Support Vector Machine (SVM) là một thuật toán học máy có giám sát, thường được sử dụng trong các bài toán phân loại. Ý tưởng chính của SVM là tìm một siêu phẳng phân tách tối ưu giữa các lớp dữ liệu sao cho khoảng cách từ siêu phẳng đó đến các điểm dữ liệu gần nhất của mỗi lớp là lớn nhất.

Các điểm dữ liệu nằm gần siêu phẳng phân tách nhất được gọi là các *support vectors*. Đây là những điểm có vai trò quan trọng trong việc xác định ranh giới phân loại của mô hình.

Trong bài toán dự đoán ung thư cổ tử cung, SVM được sử dụng để phân loại bệnh nhân thành hai nhóm:

- $y = 0$ tương ứng với bệnh nhân không có dấu hiệu ung thư cổ tử cung.
- $y = 1$ tương ứng với bệnh nhân có dấu hiệu ung thư cổ tử cung.

2.5.2 Siêu phẳng phân tách

Giả sử dữ liệu đầu vào là vector đặc trưng:

$$x = (x_1, x_2, \dots, x_d)$$

với d là số chiều dữ liệu. Trong bài toán phân loại nhị phân, SVM tìm một siêu phẳng phân tách có dạng:

$$w^T x + b = 0$$

Trong đó:

- w là vector trọng số của mô hình.

- b là hệ số bias.
- x là vector đặc trưng đầu vào.

Một điểm dữ liệu được phân loại dựa trên dấu của hàm quyết định:

$$f(x) = w^T x + b$$

Cụ thể:

$$\hat{y} = \begin{cases} 1, & \text{nếu } f(x) \geq 0 \\ 0, & \text{nếu } f(x) < 0 \end{cases}$$

Siêu phẳng trên chia không gian dữ liệu thành hai nửa không gian tương ứng với hai lớp dữ liệu khác nhau.

2.5.3 Margin và bài toán tối ưu

Trong thực tế có thể tồn tại rất nhiều siêu phẳng có khả năng phân tách dữ liệu. Tuy nhiên, SVM không lựa chọn một siêu phẳng bất kỳ mà tìm siêu phẳng sao cho khoảng cách giữa hai lớp dữ liệu là lớn nhất. Khoảng cách này được gọi là *margin*.

Hai siêu phẳng support tương ứng được xác định bởi:

$$w^T x + b = 1$$

và

$$w^T x + b = -1$$

Khoảng cách từ siêu phẳng phân tách đến điểm dữ liệu gần nhất được gọi là margin và được xác định bởi:

$$\text{margin} = \min_n \frac{y_n(w^T x_n + b)}{\|w\|_2}.$$

Do có thể nhân đồng thời w và b với một hằng số dương mà không làm thay đổi siêu phẳng phân tách, ta chuẩn hóa sao cho với các điểm gần siêu phẳng nhất:

$$y_n(w^T x_n + b) = 1.$$

Khi đó, bài toán cực đại hóa margin tương đương với bài toán:

$$\min_{w,b} \frac{1}{2} \|w\|_2^2$$

với ràng buộc:

$$y_n(w^T x_n + b) \geq 1, \quad n = 1, 2, \dots, N.$$

Trong đó:

- x_i là vector đặc trưng của mẫu thứ i .
- $y_i \in \{-1, 1\}$ là nhãn lớp tương ứng.

Trong lý thuyết SVM, nhãn thường được mã hóa dưới dạng $y_i \in \{-1, 1\}$. Tuy nhiên, trong bộ dữ liệu Biopsy, nhãn ban đầu có dạng 0 và 1, nên khi huấn luyện mô hình có thể ánh xạ $0 \rightarrow -1, 1 \rightarrow 1$, sau đó đổi kết quả dự đoán về dạng 0/1 để diễn giải.

Các điểm dữ liệu thỏa mãn dấu bằng trong điều kiện trên chính là các *support vectors*.

2.5.4 Hard Margin và Soft Margin SVM

Hard Margin SVM

Hard Margin SVM được sử dụng trong trường hợp dữ liệu có thể phân tách tuyến tính hoàn toàn. Khi đó, mọi điểm dữ liệu đều phải được phân loại chính xác và nằm ngoài vùng margin.

Tuy nhiên, trong thực tế dữ liệu thường chứa nhiễu hoặc tồn tại sự chồng lấn giữa các lớp dữ liệu. Đặc biệt đối với dữ liệu y tế, việc phân tách tuyến tính hoàn toàn thường khó đạt được. Nếu sử dụng Hard Margin SVM trong các trường hợp này, mô hình có thể hoạt động kém hiệu quả hoặc không tìm được nghiệm phù hợp.

Soft Margin SVM

Để khắc phục hạn chế trên, Soft Margin SVM cho phép một số điểm dữ liệu nằm trong vùng margin hoặc bị phân loại sai. Khi đó, biến slack ξ_i được đưa vào mô hình:

$$y_i(w^T x_i + b) \geq 1 - \xi_i$$

với $\xi_i \geq 0$.

Trong đó:

- $\xi_i = 0$: điểm dữ liệu nằm ngoài margin.
- $0 < \xi_i < 1$: điểm dữ liệu nằm trong margin nhưng vẫn được phân loại đúng.
- $\xi_i > 1$: điểm dữ liệu bị phân loại sai.

Bài toán tối ưu của Soft Margin SVM trở thành:

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{n=1}^N \xi_n$$

với điều kiện ràng buộc

$$\begin{aligned} 1 - \xi_n - y_n(\mathbf{w}^T \mathbf{x}_n + b) &\leq 0 \\ -\xi_n &\leq 0, \forall n = 1, 2, \dots, N. \end{aligned}$$

Trong đó:

- $\|\mathbf{w}\|_2^2$ giúp cực đại hóa margin.
- $\sum_{i=1}^n \xi_i$ là tổng mức độ vi phạm margin.
- C là tham số điều chỉnh mức độ phạt đối với các điểm vi phạm.

Nếu C lớn, mô hình ưu tiên phân loại đúng nhiều điểm dữ liệu huấn luyện hơn nhưng dễ xảy ra overfitting. Nếu C nhỏ, mô hình cho phép nhiều điểm nằm trong margin hơn để tăng khả năng tổng quát hóa.

Trong đề tài này, Soft Margin SVM được sử dụng do dữ liệu thực tế có thể chứa nhiễu và không phân tách tuyến tính hoàn toàn.

2.5.5 Kernel SVM

Trong thực tế, không phải mọi bộ dữ liệu đều có thể được phân tách tốt bằng một siêu phẳng tuyến tính trong không gian đặc trưng ban đầu. Đối với các bài toán có ranh giới phân loại phi tuyến, việc sử dụng SVM tuyến tính có thể không đạt hiệu quả cao. Do đó, Kernel SVM được sử dụng nhằm mở rộng khả năng phân loại của SVM cho các trường hợp dữ liệu không tách tuyến tính.

Ý tưởng chính của Kernel SVM là ánh xạ dữ liệu từ không gian đặc trưng ban đầu sang một không gian mới có số chiều cao hơn thông qua một phép biến đổi:

$$\Phi : x \rightarrow \Phi(x)$$

Trong không gian mới này, dữ liệu có thể trở nên tuyến tính hoặc gần tuyến tính hơn, từ đó SVM có thể tìm được siêu phẳng phân tách phù hợp. Nói cách khác, một bài toán có ranh giới phi tuyến trong không gian ban đầu có thể được chuyển thành bài toán phân tách tuyến tính trong không gian đặc trưng mới.

Tuy nhiên, nếu tính trực tiếp phép biến đổi $\Phi(x)$ cho toàn bộ dữ liệu, chi phí tính toán có thể rất lớn, đặc biệt khi không gian mới có số chiều cao. Để khắc phục vấn đề này, Kernel SVM sử dụng kỹ thuật Kernel Trick. Thay vì tính trực tiếp tọa độ của các điểm dữ liệu trong không gian mới, ta chỉ cần tính tích vô hướng giữa hai điểm sau khi biến đổi thông qua hàm kernel:

$$K(x_i, x_j) = \Phi(x_i)^T \Phi(x_j)$$

Nhờ đó, mô hình có thể khai thác được thông tin trong không gian đặc trưng nhiều chiều mà không cần biểu diễn tường minh các đặc trưng mới. Đây là điểm quan trọng giúp Kernel SVM xử lý hiệu quả các bài toán phân loại phi tuyến.

Hàm quyết định của Kernel SVM có dạng:

$$f(x) = \text{sign} \left(\sum_{i \in S} \alpha_i y_i K(x_i, x) + b \right)$$

Trong đó:

- S là tập các support vectors.
- α_i là hệ số Lagrange tương ứng với mẫu huấn luyện thứ i .
- y_i là nhãn của mẫu huấn luyện.
- $K(x_i, x)$ là hàm kernel đo độ tương đồng giữa mẫu huấn luyện x_i và mẫu cần dự đoán x trong không gian đặc trưng mới.
- b là hệ số chặn của mô hình.

Một số hàm kernel phổ biến gồm:

Linear Kernel:

$$K(x_i, x_j) = x_i^T x_j$$

Linear Kernel tương ứng với SVM tuyến tính, phù hợp khi dữ liệu có thể được phân tách tương đối tốt bằng siêu phẳng tuyến tính.

Polynomial Kernel:

$$K(x_i, x_j) = (x_i^T x_j + c)^d$$

Polynomial Kernel cho phép mô hình học các quan hệ phi tuyến dạng đa thức giữa các đặc trưng. Trong đó, d là bậc của đa thức và c là hằng số điều chỉnh.

Radial Basis Function Kernel (RBF):

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$$

RBF Kernel là một trong những kernel được sử dụng phổ biến nhất do có khả năng mô hình hóa ranh giới phân loại

phi tuyến linh hoạt. Tham số γ điều khiển mức độ ảnh hưởng của từng điểm dữ liệu. Nếu γ quá lớn, mô hình có thể học quá chi tiết dữ liệu huấn luyện và dẫn đến overfitting. Ngược lại, nếu γ quá nhỏ, ranh giới phân loại có thể quá đơn giản và gây underfitting.

Trong đề tài này, nhóm sử dụng SVM với các dạng dữ liệu khác nhau gồm dữ liệu gốc, dữ liệu sau PCA và dữ liệu sau LDA. Do bộ dữ liệu y tế có nhiều đặc trưng nguy cơ và mối quan hệ giữa các đặc trưng với biến mục tiêu có thể không tuyến tính, Kernel SVM, đặc biệt là RBF Kernel, là lựa chọn phù hợp để mô hình học được ranh giới phân loại linh hoạt hơn so với SVM tuyến tính. Tuy nhiên, các tham số như C và γ cần được lựa chọn phù hợp để cân bằng giữa khả năng phân loại trên tập huấn luyện và khả năng tổng quát hóa trên dữ liệu mới.

2.6 Thuật toán K-Means

2.6.1 Giới thiệu

K-Means là một trong những thuật toán phân cụm phổ biến nhất trong học máy không giám sát (*Unsupervised Learning*). Mục tiêu của thuật toán là phân chia tập dữ liệu thành K cụm dữ liệu sao cho các điểm dữ liệu trong cùng một cụm có mức độ tương đồng cao, trong khi các điểm thuộc các cụm khác nhau có mức độ khác biệt lớn hơn.

Khác với các bài toán phân loại có giám sát, trong bài toán phân cụm ta chỉ có dữ liệu đầu vào x_n mà không có nhãn đầu ra tương ứng.

Trong đề tài này, thuật toán K-Means được sử dụng nhằm:

- Phân tích cấu trúc tiềm ẩn của dữ liệu.
- Quan sát khả năng hình thành các nhóm dữ liệu tự nhiên.
- Đánh giá mối liên hệ giữa các cụm dữ liệu với nhãn thực tế.
- Hỗ trợ trực quan hóa dữ liệu sau khi giảm chiều.

2.6.2 Biểu diễn dữ liệu

Giả sử tập dữ liệu gồm:

$$X = \{x_n\}_{n=1}^N$$

trong đó $x_n \in \mathbb{R}^d$ là vector đặc trưng của mẫu dữ liệu thứ n .

Thuật toán cần phân chia dữ liệu thành K cụm dữ liệu với $1 < K < N$. Mỗi cụm được đại diện bởi một tâm cụm (*centroid*):

$$M = \{m_k\}_{k=1}^K$$

Trong đó m_k là tâm cụm thứ k .

2.6.3 Biến ẩn trong K-Means

Để biểu diễn việc một điểm dữ liệu thuộc về cụm nào, thuật toán sử dụng biến ẩn $y_{n,j} \in \{0, 1\}$.

Trong đó:

- $y_{n,j} = 1$ nếu điểm dữ liệu x_n thuộc cụm thứ j .
- $y_{n,j} = 0$ trong trường hợp ngược lại.

Mỗi điểm dữ liệu chỉ thuộc đúng một cụm, do đó:

$$\sum_{j=1}^K y_{n,j} = 1$$

Biến $y_{n,j}$ được xem như một *latent variable* giúp mô tả cấu trúc cụm của dữ liệu.

2.6.4 Hàm mục tiêu của K-Means

K-Means thực chất là bài toán tối thiểu hóa tổng phương sai nội bộ (*within-class variance*) của các cụm dữ liệu.

Giả sử các điểm dữ liệu được phân vào cụm thứ k , tổng phương sai nội bộ của cụm đó được xác định bởi:

$$\sum_{x_n \in \text{Cluster}_k} \|x_n - m_k\|_2^2$$

Tổng phương sai nội bộ trên toàn bộ các cụm được xác định bởi:

$$L(Y, M) = \sum_{n=1}^N \sum_{j=1}^K y_{n,j} \|x_n - m_j\|_2^2$$

Trong đó:

- Y : tập các biến ẩn $y_{n,j}$.
- M : tập các tâm cụm.
- $\|x_n - m_j\|_2^2$: khoảng cách Euclidean bình phương giữa điểm dữ liệu và tâm cụm.

Mục tiêu của thuật toán là tìm:

$$(Y^*, M^*) = \arg \min_{Y, M} L(Y, M)$$

với các ràng buộc:

$$y_{n,j} \in \{0, 1\}$$

và:

$$\sum_{j=1}^K y_{n,j} = 1$$

Việc tối thiểu hóa hàm mất mát trên giúp các điểm dữ liệu trong cùng một cụm nằm gần nhau hơn.

2.6.5 Khoảng cách Euclidean

Trong thuật toán K-Means, khoảng cách giữa các điểm dữ liệu thường được tính bằng khoảng cách Euclidean.

Khoảng cách giữa hai điểm dữ liệu:

$$x_i = (x_{i1}, x_{i2}, \dots, x_{id})$$

và:

$$x_j = (x_{j1}, x_{j2}, \dots, x_{jd})$$

được xác định bởi:

$$d(x_i, x_j) = \sqrt{\sum_{m=1}^d (x_{im} - x_{jm})^2}$$

Khoảng cách này phản ánh mức độ tương đồng giữa các điểm dữ liệu trong không gian đặc trưng. Các điểm dữ liệu có khoảng cách nhỏ thường có xu hướng thuộc cùng một cụm.

2.6.6 Quy tắc gán cụm

Giả sử tại một bước lặp đã biết các tâm cụm hiện tại: $\{m_c\}_{c=1}^K$. Mỗi điểm dữ liệu sẽ được gán vào cụm có tâm gần nhất. Cụ thể, $y_{n,j} = 1$ khi và chỉ khi:

$$\|x_n - m_j\|_2^2 = \min_c \|x_n - m_c\|_2^2$$

Ngược lại: $y_{n,j} = 0$.

Điều này có nghĩa là mỗi điểm dữ liệu sẽ thuộc về cụm có khoảng cách Euclidean nhỏ nhất tới tâm cụm.

2.6.7 Cập nhật tâm cụm

Sau khi hoàn thành bước gán cụm, tâm cụm mới được cập nhật bằng trung bình cộng của tất cả các điểm dữ liệu thuộc cụm đó. Tâm cụm thứ k được tính theo công thức:

$$m_k = \frac{\sum_{n=1}^N y_{n,k} x_n}{\sum_{n=1}^N y_{n,k}}$$

Trong đó:

- Tử số là tổng các điểm dữ liệu thuộc cụm thứ k .
- Mẫu số là số lượng phần tử trong cụm.

Việc cập nhật này giúp tâm cụm tiến gần hơn tới vùng có mật độ dữ liệu cao.

2.6.8 Các bước thực hiện thuật toán K-Means

Thuật toán K-Means được thực hiện theo quy trình lặp gồm các bước sau:

1. **Bước 1: Khởi tạo tâm cụm:** Chọn ngẫu nhiên K điểm dữ liệu làm tâm cụm ban đầu.
2. **Bước 2: Gán cụm cho dữ liệu:** Với mỗi điểm dữ liệu x_n , tính khoảng cách từ điểm đó tới tất cả các tâm cụm và gán điểm vào cụm có tâm gần nhất.
3. **Bước 3: Cập nhật tâm cụm:** Tính lại tâm cụm bằng trung bình cộng của các điểm dữ liệu thuộc cụm tương ứng.
4. **Bước 4: Kiểm tra điều kiện dừng:** Thuật toán tiếp tục lặp lại hai bước trên cho đến khi tâm cụm không thay đổi đáng kể, hoặc số vòng lặp đạt giới hạn cho trước.

2.6.9 Lựa chọn số cụm K bằng Elbow Method và Silhouette Score

Trong thuật toán K-Means, số cụm K cần được xác định trước khi huấn luyện mô hình. Việc lựa chọn K phù hợp có ảnh hưởng trực tiếp đến chất lượng phân cụm. Nếu K quá nhỏ, các cụm khác nhau có thể bị gộp chung; ngược lại, nếu K quá lớn, dữ liệu có thể bị chia thành nhiều cụm nhỏ và khó diễn giải.

Để lựa chọn số cụm phù hợp, nhóm sử dụng Elbow Method. Phương pháp này dựa trên giá trị WCSS (Within-Cluster Sum of Squares), là tổng bình phương khoảng cách từ các điểm dữ liệu đến tâm cụm tương ứng. WCSS được tính theo công thức:

$$\text{WCSS} = \sum_{i=1}^K \sum_{x_j \in C_i} \|x_j - \mu_i\|_2^2 \quad (26)$$

Trong đó:

- K : là số cụm.
- C_i : là cụm thứ i .
- x_j : là điểm dữ liệu thuộc cụm C_i .
- μ_i : là tâm của cụm C_i .

Khi tăng số cụm K , giá trị WCSS thường giảm dần. Tuy nhiên, sau một giá trị K nhất định, mức giảm của WCSS không còn đáng kể. Điểm tại đó đường cong WCSS bắt đầu giảm chậm lại và tạo thành dạng “khuỷu tay” được xem là giá trị K phù hợp. Cách thực hiện Elbow Method gồm các bước: chạy K-Means với nhiều giá trị K khác nhau, tính WCSS tương ứng với từng K , vẽ biểu đồ giữa K và WCSS, sau đó chọn giá trị K tại vị trí đường cong bắt đầu giảm chậm lại.

Bên cạnh Elbow Method, nhóm sử dụng thêm Silhouette Score để đánh giá chất lượng phân cụm. Chỉ số này cho biết một điểm dữ liệu được gán vào cụm hiện tại có phù hợp hay không, dựa trên khoảng cách của điểm đó với các điểm trong cùng cụm và các điểm ở cụm gần nhất khác. Với mỗi điểm dữ liệu x_i , Silhouette Score được tính theo công thức:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \quad (27)$$

Trong đó:

- $a(i)$: là khoảng cách trung bình từ điểm x_i đến các điểm khác trong cùng cụm.
- $b(i)$: là khoảng cách trung bình nhỏ nhất từ điểm x_i đến các điểm thuộc cụm khác gần nhất.

Giá trị Silhouette Score nằm trong khoảng từ -1 đến 1 . Giá trị càng gần 1 cho thấy các cụm được phân tách tốt; giá trị gần 0 cho thấy các cụm có sự chồng lấn; giá trị âm cho thấy điểm dữ liệu có thể bị gán sai cụm.

Như vậy, Elbow Method được sử dụng để hỗ trợ lựa chọn số cụm K , còn Silhouette Score được dùng để đánh giá mức độ hợp lý của kết quả phân cụm. Việc kết hợp hai phương pháp giúp lựa chọn số cụm có cơ sở hơn thay vì chỉ dựa vào quan sát trực quan.

3 KẾT QUẢ THỰC NGHIỆM VÀ ĐÁNH GIÁ

3.1 Thiết lập thực nghiệm

Sau khi hoàn thành các bước tiền xử lý dữ liệu, bộ dữ liệu còn lại 858 mẫu và 34 thuộc tính, trong đó biến mục tiêu là *Biopsy*. Sau khi tách biến đầu vào và đầu ra, tập đặc trưng đầu vào có 33 thuộc tính, biến mục tiêu có 2 lớp: lớp 0 gồm 803 mẫu và lớp 1 gồm 55 mẫu. Điều này cho thấy dữ liệu bị mất cân bằng rõ rệt, trong đó lớp 1 chiếm tỷ lệ nhỏ so với lớp 0.

Để đánh giá mô hình một cách khách quan hơn, nhóm không chia trực tiếp toàn bộ dữ liệu theo các tỷ lệ train:test, mà thực hiện theo hai bước:

- **Bước 1:** Tách riêng 20% dữ liệu làm tập *Test* cố định.
- **Bước 2:** Phần dữ liệu còn lại được chia thành *Train* và *Validation* theo ba tỷ lệ 4:1, 7:3 và 6:4.

Sau bước tách *Test* cố định, dữ liệu được chia thành:

Bảng 2: Phân bố dữ liệu sau khi tách tập *Test* cố định

Tập dữ liệu	Số mẫu	Lớp 0	Lớp 1
Toàn bộ dữ liệu	858	803	55
X_{remain}	686	642	44
Test cố định	172	161	11

Tập *Test* cố định gồm 172 mẫu, trong đó có 161 mẫu lớp 0 và 11 mẫu lớp 1. Tập này được giữ nguyên trong toàn bộ quá trình thực nghiệm và chỉ dùng để đánh giá khả năng tổng quát hóa cuối cùng của mô hình.

Các mô hình được sử dụng gồm:

- K-Nearest Neighbors(KNN);
- Logistic Regression;
- Support Vector Machine(SVM).

Các mô hình được huấn luyện và đánh giá trên ba dạng dữ liệu:

- Dữ liệu gốc sau chuẩn hóa;
- Dữ liệu sau giảm chiều bằng PCA;
- Dữ liệu sau giảm chiều bằng LDA.

Do dữ liệu mất cân bằng, SMOTE được áp dụng trên tập *Train* nhằm cân bằng số lượng mẫu giữa hai lớp. SMOTE chỉ được áp dụng trên tập *Train*, không áp dụng trên *Validation* và *Test* để tránh làm sai lệch kết quả đánh giá.

Các chỉ số đánh giá gồm *Accuracy*, *Precision*, *Recall*, *F1-score* và *Confusion Matrix*. Trong bài toán dự đoán ung thư cổ tử cung, *Recall* của lớp 1 được ưu tiên vì việc bỏ sót bệnh nhân có nguy cơ mắc bệnh gây hậu quả nghiêm trọng hơn so với dự đoán nhầm một số mẫu không bệnh thành có bệnh.

3.2 Kết quả với tỷ lệ Train:Validation = 4:1

Với tỷ lệ Train:Validation = 4:1, phần X_{remain} được chia thành 548 mẫu train và 138 mẫu validation. Tập train bao gồm 513 mẫu thuộc lớp 0 và 35 mẫu thuộc lớp 1; sau khi áp dụng kỹ thuật SMOTE, tập train đã được cân bằng

với phân phối [513, 513]. Tập validation bao gồm 129 mẫu lớp 0 và 9 mẫu lớp 1. Số chiều dữ liệu sau khi thực hiện PCA là 19, với tổng phương sai giữ lại đạt khoảng 96,00%.

Bảng 3: Kết quả đánh giá các mô hình trên tập Validation tỷ lệ 4:1

Mô hình	Dữ liệu	Accuracy	Precision	Recall	F1-score
KNN	Original	0.9638	0.7500	0.6667	0.7059
	PCA	0.9638	0.7500	0.6667	0.7059
	LDA	0.9710	0.7273	0.8889	0.8000
Logistic Regression	Original	0.9638	0.7000	0.7778	0.7368
	PCA	0.9783	0.8000	0.8889	0.8421
	LDA	0.9783	0.8000	0.8889	0.8421
SVM	Original	0.9348	0.5000	0.2222	0.3077
	PCA	0.9275	0.4000	0.2222	0.2857
	LDA	0.9783	0.8000	0.8889	0.8421

Bảng 4: Kết quả trên tập Test cố định với tỷ lệ 4:1

Mô hình	Dữ liệu	Accuracy	Precision	Recall	F1-score
KNN	Original	0.9477	0.5714	0.7273	0.6400
	PCA	0.9535	0.6154	0.7273	0.6667
	LDA	0.9419	0.5294	0.8182	0.6429
Logistic Regression	Original	0.9651	0.6923	0.8182	0.7500
	PCA	0.9651	0.6923	0.8182	0.7500
	LDA	0.9593	0.6429	0.8182	0.7200
SVM	Original	0.9477	0.5833	0.6364	0.6087
	PCA	0.9477	0.6000	0.5455	0.5714
	LDA	0.9593	0.6429	0.8182	0.7200

Ở tỷ lệ 4:1, mô hình Logistic Regression trên dữ liệu gốc và dữ liệu sau giảm chiều bằng PCA cho kết quả tốt nhất trên tập Test cố định. Cụ thể, cả hai trường hợp đều đạt $Accuracy = 0.9651$, $Precision = 0.6923$, $Recall = 0.8182$ và $F1-score = 0.7500$. Kết quả này cho thấy mô hình phát hiện đúng 9 trên 11 mẫu thuộc lớp 1 trong tập Test cố định.

Đối với KNN, kết quả tốt nhất đạt được khi sử dụng dữ liệu sau giảm chiều bằng PCA với $Accuracy = 0.9535$ và $F1-score = 0.6667$. Tuy nhiên, $Recall$ của KNN-PCA chỉ đạt 0.7273, thấp hơn Logistic Regression. Khi sử dụng LDA, KNN đạt $Recall = 0.8182$ nhưng $Precision$ giảm xuống còn 0.5294, làm cho $F1-score$ không cao bằng Logistic Regression.

Đối với SVM, mô hình trên dữ liệu gốc và dữ liệu PCA có $Recall$ thấp hơn, lần lượt là 0.6364 và 0.5455. Tuy

nhien, khi kết hợp với LDA, SVM được cải thiện rõ rệt với *Recall* tăng lên 0.8182 và *F1-score* đạt 0.7200. Điều này cho thấy LDA giúp SVM phân biệt hai lớp tốt hơn trong trường hợp dữ liệu mất cân bằng.

Nhìn chung, với tỷ lệ 4:1, Logistic Regression trên dữ liệu gốc và PCA là hai mô hình cho kết quả ổn định và tốt nhất. Do bài toán dự đoán ung thư cổ tử cung ưu tiên phát hiện đúng các mẫu lớp 1, mô hình có *Recall* cao đồng thời *F1-score* tốt như Logistic Regression là lựa chọn phù hợp hơn so với KNN và SVM.

3.3 Kết quả với tỷ lệ Train:Validation = 7:3

Với tỷ lệ *Train:Validation* = 7:3, phần X_{remain} được chia thành 480 mẫu *Train* và 206 mẫu *Validation*. Tập *Train* gồm 449 mẫu lớp 0 và 31 mẫu lớp 1; sau khi áp dụng SMOTE, tập *Train* được cân bằng thành [449, 449]. Tập *Validation* gồm 193 mẫu lớp 0 và 13 mẫu lớp 1. Số chiều dữ liệu sau PCA là 18, với tổng phương sai giữ lại khoảng 95.12%.

Bảng 5: Kết quả trên tập Validation với tỷ lệ 7:3

Mô hình	Dữ liệu	Accuracy	Precision	Recall	F1-score
KNN	Original	0.9369	0.5000	0.4615	0.4800
	PCA	0.9320	0.4667	0.5385	0.5000
	LDA	0.9757	0.7500	0.9231	0.8276
Logistic Regression	Original	0.9709	0.7059	0.9231	0.8000
	PCA	0.9612	0.6471	0.8462	0.7333
	LDA	0.9757	0.7500	0.9231	0.8276
SVM	Original	0.9369	0.5000	0.1538	0.2353
	PCA	0.9417	0.5556	0.3846	0.4545
	LDA	0.9757	0.7500	0.9231	0.8276

Bảng 6: Kết quả trên tập Test cố định với tỷ lệ 7:3

Mô hình	Dữ liệu	Accuracy	Precision	Recall	F1-score
KNN	Original	0.9419	0.5385	0.6364	0.5833
	PCA	0.9186	0.4000	0.5455	0.4615
	LDA	0.9593	0.6429	0.8182	0.7200
Logistic Regression	Original	0.9593	0.6429	0.8182	0.7200
	PCA	0.9593	0.6429	0.8182	0.7200
	LDA	0.9593	0.6429	0.8182	0.7200
SVM	Original	0.9419	0.5455	0.5455	0.5455
	PCA	0.9302	0.4615	0.5455	0.5000
	LDA	0.9593	0.6429	0.8182	0.7200

Ở tỷ lệ 7:3, các mô hình kết hợp với LDA cho kết quả tốt trên tập *Validation*. Cụ thể, KNN-LDA, Logistic Regression-LDA và SVM-LDA đều đạt $Accuracy = 0.9757$, $Precision = 0.7500$, $Recall = 0.9231$ và $F1-score = 0.8276$. Đây là các kết quả cao nhất trên tập *Validation*, cho thấy LDA giúp cải thiện khả năng phân tách giữa hai lớp, đặc biệt trong bối cảnh dữ liệu mất cân bằng.

Đối với Logistic Regression, mô hình trên dữ liệu gốc cũng cho kết quả khá tốt với $Recall = 0.9231$ và $F1-score = 0.8000$. Tuy nhiên, khi sử dụng PCA, các chỉ số giảm nhẹ, với $Recall = 0.8462$ và $F1-score = 0.7333$. Điều này cho thấy PCA giúp giảm chiều dữ liệu nhưng có thể làm mất một phần thông tin quan trọng phục vụ việc phân loại lớp 1.

Đối với SVM, mô hình trên dữ liệu gốc và dữ liệu PCA cho kết quả chưa tốt trên tập *Validation*, đặc biệt $Recall$ chỉ đạt lần lượt 0.1538 và 0.3846. Tuy nhiên, khi sử dụng LDA, SVM được cải thiện rõ rệt với $Recall$ tăng lên 0.9231 và $F1-score$ đạt 0.8276.

Khi đánh giá trên tập *Test* cố định, các mô hình tốt nhất gồm KNN-LDA, Logistic Regression trên cả ba dạng dữ liệu và SVM-LDA đều đạt $Accuracy = 0.9593$, $Precision = 0.6429$, $Recall = 0.8182$ và $F1-score = 0.7200$. Kết quả này tương ứng với việc mô hình phát hiện đúng 9 trên 11 mẫu thuộc lớp 1 trong tập *Test* cố định.

Nhìn chung, với tỷ lệ 7:3, LDA giúp cải thiện rõ rệt kết quả trên tập *Validation*, đặc biệt đối với SVM. Tuy nhiên, trên tập *Test* cố định, hiệu quả của LDA không vượt trội rõ rệt so với Logistic Regression trên dữ liệu gốc hoặc dữ liệu PCA. Vì vậy, Logistic Regression vẫn là mô hình ổn định hơn khi xét cả khả năng phát hiện lớp 1 và khả năng tổng quát hóa trên tập kiểm tra cố định.

3.4 Kết quả với tỷ lệ Train:Validation = 6:4

Với tỷ lệ *Train:Validation* = 6:4, phần dữ liệu còn lại sau khi tách tập *Test* cố định được chia thành 411 mẫu *Train* và 275 mẫu *Validation*. Tập *Train* gồm 385 mẫu lớp 0 và 26 mẫu lớp 1; sau khi áp dụng SMOTE, tập *Train* được cân bằng thành [385, 385]. Tập *Validation* gồm 257 mẫu lớp 0 và 18 mẫu lớp 1. Số chiều dữ liệu sau PCA là 18, với tổng phương sai giữ lại khoảng 95.13%.

Bảng 7: Kết quả trên tập *Validation* với tỷ lệ 6:4

Mô hình	Dữ liệu	Accuracy	Precision	Recall	F1-score
KNN	Original	0.9382	0.5294	0.5000	0.5143
	PCA	0.9273	0.4545	0.5556	0.5000
	LDA	0.9636	0.7000	0.7778	0.7368
Logistic Regression	Original	0.9527	0.5926	0.8889	0.7111
	PCA	0.9600	0.6842	0.7222	0.7027
	LDA	0.9673	0.6957	0.8889	0.7805
SVM	Original	0.9491	0.6667	0.4444	0.5333
	PCA	0.9455	0.6000	0.5000	0.5455
	LDA	0.9636	0.6667	0.8889	0.7619

Bảng 8: Kết quả trên tập Test cố định với tỷ lệ 6:4

Mô hình	Dữ liệu	Accuracy	Precision	Recall	F1-score
KNN	Original	0.9302	0.4545	0.4545	0.4545
	PCA	0.9244	0.4167	0.4545	0.4348
	LDA	0.9593	0.6429	0.8182	0.7200
Logistic Regression	Original	0.9593	0.6250	0.9091	0.7407
	PCA	0.9419	0.5385	0.6364	0.5833
	LDA	0.9651	0.6923	0.8182	0.7500
SVM	Original	0.9360	0.5000	0.4545	0.4762
	PCA	0.9302	0.4545	0.4545	0.4545
	LDA	0.9593	0.6429	0.8182	0.7200

Ở tỷ lệ 6:4, Logistic Regression trên dữ liệu gốc cho kết quả nổi bật nhất nếu xét theo *Recall* trên tập *Test* cố định. Mô hình đạt $Recall = 0.9091$, tức là phát hiện đúng 10 trên 11 mẫu thuộc lớp 1. Đây là kết quả quan trọng trong bài toán dự đoán nguy cơ ung thư cổ tử cung, vì việc phát hiện đúng các trường hợp có nguy cơ mắc bệnh cần được ưu tiên hơn so với việc chỉ tối đa hóa *Accuracy*.

Khi sử dụng PCA, hiệu quả của một số mô hình không được cải thiện rõ rệt. Đặc biệt, Logistic Regression trên dữ liệu PCA chỉ đạt $Recall = 0.6364$ trên tập *Test*, thấp hơn so với khi sử dụng dữ liệu gốc. Điều này cho thấy PCA giúp giảm chiều dữ liệu nhưng có thể làm mất một phần thông tin quan trọng phục vụ cho việc phân biệt lớp 1.

Ngược lại, LDA giúp cải thiện kết quả khá rõ đối với KNN và SVM. Cụ thể, KNN-LDA và SVM-LDA đều đạt $Recall = 0.8182$ trên tập *Test*, cao hơn so với khi dùng dữ liệu gốc hoặc PCA. Điều này phù hợp với đặc điểm của LDA là phương pháp giảm chiều có giám sát, có sử dụng thông tin nhãn để tìm hướng chiếu giúp phân tách các lớp tốt hơn.

Nhìn chung, với tỷ lệ $Train:Validation = 6:4$, Logistic Regression trên dữ liệu gốc là mô hình phù hợp nhất nếu ưu tiên *Recall*, trong khi Logistic Regression kết hợp LDA cho kết quả cân bằng hơn giữa *Accuracy*, *Precision*, *Recall* và *F1-score*. Do bài toán thuộc lĩnh vực y tế, mô hình Logistic Regression trên dữ liệu gốc được xem là lựa chọn đáng chú ý nhất vì có khả năng giảm số ca bệnh bị bỏ sót.

3.5 So sánh tổng hợp các mô hình trên tập Test cố định

Bảng 9: Một số kết quả tốt nhất trên tập Test cố định

Tỷ lệ	Mô hình	Dữ liệu	Accuracy	Precision	Recall	F1-score
4:1	Logistic Regression	Original	0.9651	0.6923	0.8182	0.7500
4:1	Logistic Regression	PCA	0.9651	0.6923	0.8182	0.7500
7:3	Logistic Regression	Original/PCA/LDA	0.9593	0.6429	0.8182	0.7200
7:3	KNN/SVM	LDA	0.9593	0.6429	0.8182	0.7200
6:4	Logistic Regression	Original	0.9593	0.6250	0.9091	0.7407
6:4	Logistic Regression	LDA	0.9651	0.6923	0.8182	0.7500

Từ Bảng 9 có thể thấy Logistic Regression là mô hình có kết quả ổn định nhất trên tập *Test* cố định. Ở tỷ lệ 4:1, Logistic Regression trên dữ liệu gốc và dữ liệu sau giảm chiều bằng PCA đều đạt $Accuracy = 0.9651$, $Precision = 0.6923$, $Recall = 0.8182$ và $F1-score = 0.7500$. Đây là một trong những kết quả tốt nhất xét theo độ cân bằng giữa $Precision$, $Recall$ và $F1-score$.

Ở tỷ lệ 6:4, Logistic Regression kết hợp với LDA cũng đạt $F1-score = 0.7500$. Tuy nhiên, Logistic Regression trên dữ liệu gốc với tỷ lệ 6:4 đạt $Recall$ cao nhất, bằng 0.9091. Điều này có nghĩa là mô hình phát hiện đúng 10 trên 11 mẫu thuộc lớp 1 trong tập *Test* cố định.

Trong bài toán phát hiện nguy cơ ung thư cổ tử cung, $Recall$ của lớp 1 có vai trò rất quan trọng, vì việc bỏ sót bệnh nhân có nguy cơ mắc bệnh có thể gây hậu quả nghiêm trọng. Do đó, mô hình Logistic Regression trên dữ liệu gốc với tỷ lệ $Train:Validation = 6:4$ được xem là lựa chọn phù hợp nếu mục tiêu chính là giảm số ca bệnh bị bỏ sót.

3.6 Đánh giá hiện tượng overfitting

Để kiểm tra hiện tượng overfitting, nhóm so sánh kết quả trên tập *Train* và tập *Validation*. Nếu mô hình đạt kết quả rất cao trên tập *Train* nhưng giảm mạnh trên tập *Validation*, mô hình có dấu hiệu học quá khớp dữ liệu huấn luyện.

Kết quả thực nghiệm cho thấy KNN và SVM có dấu hiệu overfitting rõ hơn Logistic Regression. Ví dụ, với tỷ lệ 7:3 trên dữ liệu gốc, KNN đạt $Recall$ trên tập *Train* bằng 1.0000 nhưng $Recall$ trên tập *Validation* chỉ đạt 0.4615. Tương tự, SVM trên dữ liệu gốc đạt $Recall$ trên tập *Train* bằng 1.0000 nhưng $Recall$ trên tập *Validation* chỉ đạt 0.1538.

Ngược lại, Logistic Regression cho kết quả ổn định hơn. Với dữ liệu gốc ở tỷ lệ 7:3, Logistic Regression đạt $Recall$ trên tập *Train* là 0.9621 và $Recall$ trên tập *Validation* là 0.9231. Mức chênh lệch này nhỏ hơn nhiều so với KNN và SVM, cho thấy mô hình có khả năng tổng quát hóa tốt hơn.

Điều này cho thấy Logistic Regression phù hợp hơn trong bài toán này khi xét đến khả năng tránh overfitting. KNN dễ bị ảnh hưởng bởi nhiễu và cấu trúc cục bộ của dữ liệu, trong khi SVM với kernel RBF có thể tạo ra ranh giới phân loại phức tạp, dẫn đến kết quả rất tốt trên tập *Train* nhưng giảm mạnh trên tập *Validation*.

3.7 Đánh giá tác động của PCA và LDA

PCA giúp giảm số chiều dữ liệu từ 33 chiều ban đầu xuống còn khoảng 18–19 chiều, đồng thời vẫn giữ lại trên 95% phương sai của dữ liệu. Cụ thể, với tỷ lệ 4:1, PCA giảm dữ liệu xuống 19 chiều và giữ lại khoảng 96.00%

phương sai. Với tỷ lệ 7:3 và 6:4, PCA giảm dữ liệu xuống 18 chiều và giữ lại khoảng 95.1% phương sai.

Tuy nhiên, PCA không phải lúc nào cũng cải thiện kết quả phân loại. Ví dụ, với tỷ lệ 6:4, Logistic Regression trên dữ liệu PCA chỉ đạt $Recall = 0.6364$ trên tập *Test*, thấp hơn đáng kể so với $Recall = 0.9091$ khi sử dụng dữ liệu gốc. Điều này cho thấy PCA giúp giảm chiều và giảm độ phức tạp tính toán, nhưng do PCA không sử dụng thông tin nhãn nên các thành phần chính được giữ lại chưa chắc là những hướng phân biệt tốt nhất giữa hai lớp.

Ngược lại, LDA thường giúp cải thiện khả năng nhận diện lớp 1, đặc biệt đối với KNN và SVM. Ví dụ, với tỷ lệ 7:3 trên tập *Test*, KNN khi sử dụng dữ liệu gốc đạt $Recall = 0.6364$, trong khi KNN kết hợp với LDA đạt $Recall = 0.8182$. Tương tự, SVM trên dữ liệu gốc đạt $Recall = 0.5455$, còn SVM kết hợp với LDA đạt $Recall = 0.8182$.

Kết quả này phù hợp với đặc điểm của LDA. Khác với PCA, LDA là phương pháp giảm chiều có giám sát, tức là có sử dụng thông tin nhãn lớp để tìm hướng chiếu sao cho khả năng phân tách giữa các lớp là tốt nhất. Vì vậy, trong bài toán phân loại nhị phân với dữ liệu mất cân bằng, LDA có thể hỗ trợ mô hình nhận diện lớp thiểu số tốt hơn.

3.8 Đánh giá theo Confusion Matrix

Dựa trên các ma trận nhầm lẫn, có thể thấy các mô hình đều dự đoán tốt lớp 0 do lớp này chiếm số lượng lớn trong dữ liệu. Sự khác biệt giữa các mô hình chủ yếu nằm ở khả năng phát hiện lớp 1.

Một số ma trận nhầm lẫn tiêu biểu trên tập *Test* cố định được trình bày trong Bảng 10.

Bảng 10: Một số ma trận nhầm lẫn tiêu biểu trên tập *Test* cố định

Mô hình	Dữ liệu	Tỷ lệ	Confusion Matrix	Nhận xét
Logistic Regression	Original	6:4	$\begin{bmatrix} 155 & 6 \\ 1 & 10 \end{bmatrix}$	Chỉ bỏ sót 1/11 mẫu lớp 1, Recall cao nhất
Logistic Regression	LDA	6:4	$\begin{bmatrix} 157 & 4 \\ 2 & 9 \end{bmatrix}$	F1-score cao, ít dự đoán nhầm lớp 0 hơn
KNN	Original	6:4	$\begin{bmatrix} 155 & 6 \\ 6 & 5 \end{bmatrix}$	Bỏ sót 6/11 mẫu lớp 1
SVM	Original	6:4	$\begin{bmatrix} 156 & 5 \\ 6 & 5 \end{bmatrix}$	Recall thấp, chưa phù hợp nếu ưu tiên phát hiện bệnh
SVM	LDA	6:4	$\begin{bmatrix} 156 & 5 \\ 2 & 9 \end{bmatrix}$	LDA cải thiện rõ khả năng phát hiện lớp 1

Trong các ma trận nhầm lẫn trên, mỗi ma trận có dạng:

$$\begin{bmatrix} TN & FP \\ FN & TP \end{bmatrix}$$

Trong đó TN là số mẫu lớp 0 được dự đoán đúng, FP là số mẫu lớp 0 bị dự đoán nhầm thành lớp 1, FN là số mẫu lớp 1 bị bỏ sót và TP là số mẫu lớp 1 được phát hiện đúng.

Từ Bảng 10, có thể thấy Logistic Regression trên dữ liệu gốc với tỷ lệ 6:4 có ưu điểm nổi bật là chỉ bỏ sót 1 mẫu lớp 1. Cụ thể, mô hình phát hiện đúng 10 trên 11 mẫu thuộc lớp 1, tương ứng với $Recall = 0.9091$. Trong bối cảnh

bài toán y tế, đây là kết quả đáng chú ý vì mô hình giảm được nguy cơ bỏ sót bệnh nhân có khả năng mắc bệnh.

Bên cạnh đó, Logistic Regression kết hợp LDA cũng cho kết quả tốt với 9 mẫu lớp 1 được phát hiện đúng và chỉ 2 mẫu lớp 1 bị bỏ sót. Tuy nhiên, nếu ưu tiên cao nhất là giảm số lượng mẫu bệnh bị bỏ sót, Logistic Regression trên dữ liệu gốc vẫn là lựa chọn phù hợp hơn.

Đối với KNN và SVM trên dữ liệu gốc, số lượng mẫu lớp 1 bị bỏ sót còn khá cao. KNN trên dữ liệu gốc bỏ sót 6/11 mẫu lớp 1, trong khi SVM trên dữ liệu gốc cũng bỏ sót 6/11 mẫu lớp 1. Điều này cho thấy hai mô hình này chưa thật sự phù hợp nếu mục tiêu chính là phát hiện tối đa các trường hợp có nguy cơ mắc bệnh.

Khi sử dụng LDA, SVM được cải thiện rõ rệt, số mẫu lớp 1 phát hiện đúng tăng lên 9/11. Kết quả này tiếp tục cho thấy LDA có tác động tích cực trong việc hỗ trợ mô hình phân biệt lớp thiếu sót tốt hơn.

3.9 Chuyển đổi bài toán phân loại sang bài toán hồi quy

Để đánh giá khả năng mô hình hóa mức độ rủi ro thay vì chỉ phân loại nhị phân, nhóm thực hiện chuyển đổi bài toán từ phân loại sang hồi quy. Thay vì sử dụng nhãn *Biopsy* (0 hoặc 1), nhóm sử dụng xác suất dự đoán lớp dương từ mô hình Logistic Regression làm biến mục tiêu:

$$y_i^{reg} = P(Biopsy = 1|x_i) \quad (28)$$

Trong đó, $y_i^{reg} \in [0, 1]$ thể hiện mức độ rủi ro liên tục của mẫu dữ liệu. Sau đó, nhóm sử dụng hai mô hình là Linear Regression và KNN Regressor để học ánh xạ từ x_i sang y_i^{reg} trên hai tập dữ liệu: dữ liệu gốc và dữ liệu sau khi giảm chiều bằng PCA (giữ lại 1/3 số chiều).

Kết quả thực nghiệm

Kết quả đánh giá dựa trên các chỉ số MAE, MSE, RMSE và R^2 được trình bày tại Bảng 11.

Bảng 11: Kết quả hồi quy sau khi chuyển đổi từ bài toán phân loại

Mô hình	Dữ liệu	MAE	MSE	RMSE	R^2
Linear Regression	Original	0.0452	0.0066	0.0812	0.8858
KNN Regressor	Original	0.0418	0.0158	0.1256	0.7271
Linear Regression	PCA (1/3)	0.0607	0.0125	0.1120	0.7830
KNN Regressor	PCA (1/3)	0.0405	0.0114	0.1068	0.8027

Nhận xét

Dựa trên bảng kết quả, chúng ta rút ra các nhận định chính như sau:

- **Hiệu quả mô hình:** Linear Regression trên dữ liệu gốc đạt kết quả tốt nhất với $R^2 = 0.8858$ và RMSE thấp nhất (0.0812). Điều này cho thấy mô hình tuyến tính xấp xỉ rất tốt xác suất đầu ra được sinh ra từ Logistic Regression.
- **Ảnh hưởng của PCA:** Khi giảm chiều dữ liệu bằng PCA, hiệu suất của Linear Regression suy giảm do mất mát một phần thông tin. Ngược lại, KNN Regressor cải thiện đáng kể (R^2 từ 0.7271 lên 0.8027), cho thấy PCA giúp giảm nhiễu và các đặc trưng dư thừa, giúp KNN hoạt động ổn định hơn trong không gian giảm chiều.
- **Kết luận:** Việc chuyển đổi bài toán phân loại sang hồi quy là khả thi. Linear Regression là lựa chọn tối ưu trên dữ liệu gốc, trong khi PCA là phương pháp tiền xử lý hiệu quả để tối ưu hóa cho KNN Regressor.

3.10 Kết quả phân cụm K-Means

Đối với bài toán phân cụm, nhóm sử dụng K-Means trên dữ liệu đầu vào sau khi bỏ qua nhãn *Biopsy*. Kết quả đánh giá phân cụm với $K = 2$ được trình bày trong Bảng 12.

Bảng 12: Kết quả đánh giá phân cụm K-Means với $K = 2$

Chỉ số	Giá trị
Silhouette Score	0.5502
Davies-Bouldin Index	1.7283
Adjusted Rand Index	0.0950

Silhouette Score đạt 0.5502 cho thấy dữ liệu có xu hướng hình thành cụm ở mức trung bình. Tuy nhiên, Adjusted Rand Index chỉ đạt 0.0950, cho thấy các cụm do K-Means tạo ra không khớp rõ ràng với nhãn *Biopsy* thực tế. Nói cách khác, cấu trúc cụm tự nhiên của dữ liệu chưa phản ánh tốt trạng thái có bệnh hay không có bệnh.

Để đánh giá rõ hơn mối quan hệ giữa các cụm thu được từ thuật toán K-Means và nhãn thực tế (*Biopsy*), nhóm thực hiện thống kê phân bố nhãn trong từng cụm như trình bày tại Bảng 13.

Bảng 13: Phân bố nhãn Biopsy trong từng cụm

Cluster	Biopsy = 0	Biopsy = 1
Cụm 0	736	43
Cụm 1	67	12

Kết quả từ Bảng 13 cho thấy cả hai cụm đều chứa đồng thời mẫu của cả hai lớp. Cụ thể, K-Means chưa phân tách được hai nhóm bệnh nhân theo đúng nhãn *Biopsy*. Xét về tỷ lệ mắc bệnh (lớp 1) trong từng cụm:

- **Cụm 0:** Tỷ lệ mẫu dương tính là:

$$\frac{43}{736 + 43} \approx 5.52\% \quad (29)$$

- **Cụm 1:** Tỷ lệ mẫu dương tính là:

$$\frac{12}{67 + 12} \approx 15.19\% \quad (30)$$

Điều này cho thấy cụm 1 có tỷ lệ mẫu thuộc lớp có dấu hiệu bệnh cao hơn cụm 0. Tuy nhiên, do số lượng mẫu lớp 1 vẫn bị phân tán trong cả hai cụm, cấu trúc cụm tự nhiên của dữ liệu chưa phản ánh tốt trạng thái có bệnh hay không có bệnh.

Kết quả này cũng phù hợp với giá trị ARI thấp. Do K-Means là thuật toán không giám sát, mô hình chỉ dựa trên khoảng cách giữa các điểm dữ liệu mà không sử dụng thông tin nhãn trong quá trình học. Bên cạnh đó, dữ liệu ban đầu bị mất cân bằng mạnh, với 803 mẫu thuộc lớp 0 và chỉ 55 mẫu thuộc lớp 1, nên thuật toán có xu hướng phân cụm theo cấu trúc tổng thể của dữ liệu thay vì tách riêng nhóm bệnh nhân có dấu hiệu bệnh.

Vì vậy, K-Means chỉ phù hợp để khảo sát cấu trúc tiềm ẩn của dữ liệu, không phù hợp để thay thế các mô hình phân loại có giám sát trong bài toán dự đoán Biopsy. Đối với mục tiêu phát hiện nguy cơ ung thư cổ tử cung, các mô hình học có giám sát như Logistic Regression, KNN và SVM vẫn phù hợp hơn.

3.11 Kết luận phần thực nghiệm

Thứ nhất, dữ liệu ban đầu bị mất cân bằng mạnh, với lớp 1 chỉ gồm 55 trên tổng số 858 mẫu. Việc áp dụng SMOTE trên tập *Train* giúp cân bằng dữ liệu huấn luyện và hỗ trợ mô hình học tốt hơn đặc trưng của lớp thiểu số. Tuy nhiên, SMOTE chỉ được áp dụng trên tập *Train*, không áp dụng trên tập *Validation* và tập *Test*, nhằm đảm bảo kết quả đánh giá phản ánh đúng khả năng tổng quát hóa của mô hình.

Thứ hai, Logistic Regression là mô hình có hiệu quả ổn định nhất trên tập *Test* cố định. Mô hình này đạt kết quả tốt trên nhiều tỷ lệ chia dữ liệu và nhiều dạng dữ liệu khác nhau. Đặc biệt, Logistic Regression trên dữ liệu gốc với tỷ lệ *Train:Validation* = 6:4 đạt *Recall* = 0.9091 trên tập *Test*, tức là phát hiện đúng 10 trên 11 mẫu lớp 1 và chỉ bỏ sót 1 mẫu.

Thứ ba, PCA giúp giảm chiều dữ liệu và giữ lại trên 95% phương sai, nhưng không luôn cải thiện hiệu quả phân loại. Trong một số trường hợp, PCA làm giảm *Recall* của lớp 1. Nguyên nhân là do PCA là phương pháp giảm chiều không giám sát, chỉ dựa trên phương sai của dữ liệu mà không sử dụng thông tin nhãn lớp. Vì vậy, các thành phần chính được giữ lại chưa chắc là những hướng có khả năng phân biệt tốt giữa hai lớp.

Thứ tư, LDA có tác động tích cực đến KNN và SVM, giúp hai mô hình này cải thiện *Recall* trên lớp 1. Điều này phù hợp với đặc điểm của LDA là phương pháp giảm chiều có giám sát, sử dụng thông tin nhãn để tìm hướng phân tách tốt hơn giữa các lớp. Tuy nhiên, Logistic Regression trên dữ liệu gốc vẫn là lựa chọn đáng chú ý nhất nếu ưu tiên phát hiện bệnh.

Thứ năm, K-Means chưa phản ánh tốt nhãn *Biopsy* do Adjusted Rand Index thấp. Vì vậy, phân cụm chỉ nên được sử dụng để tham khảo cấu trúc dữ liệu, không nên dùng thay thế mô hình phân loại có giám sát trong bài toán này.

Tóm lại, trong phạm vi đề tài. Nếu ưu tiên giảm bỏ sót bệnh nhân, chọn Logistic Regression - Original với tỷ lệ 6:4 vì *Recall* cao nhất. Nếu ưu tiên cân bằng Precision, Recall và F1-score, Logistic Regression - LDA hoặc Logistic Regression - Original/PCA ở tỷ lệ 4:1 cũng là lựa chọn tốt.

KẾT LUẬN

Trong đề tài này, nhóm đã xây dựng quy trình ứng dụng học máy nhằm dự đoán nguy cơ ung thư cổ tử cung dựa trên bộ dữ liệu *Cervical Cancer Risk Factors*. Bài toán được xác định là bài toán phân loại nhị phân với biến mục tiêu là *Biopsy*, trong đó lớp 0 biểu thị bệnh nhân không có dấu hiệu ung thư cổ tử cung và lớp 1 biểu thị bệnh nhân có dấu hiệu ung thư cổ tử cung.

Về tiền xử lý dữ liệu, nhóm đã thực hiện các bước gồm xử lý giá trị thiếu, loại bỏ các thuộc tính có tỷ lệ thiếu quá cao, chuyển đổi dữ liệu về dạng số, chuẩn hóa dữ liệu và tách biến đầu vào, đầu ra. Sau tiền xử lý, tập dữ liệu gồm 858 mẫu, trong đó có 803 mẫu thuộc lớp 0 và 55 mẫu thuộc lớp 1. Điều này cho thấy dữ liệu có sự mất cân bằng rõ rệt giữa hai lớp. Vì vậy, phương pháp SMOTE được áp dụng trên tập huấn luyện nhằm cân bằng số lượng mẫu và giúp mô hình học tốt hơn đối với lớp thiểu số.

Để đánh giá mô hình một cách khách quan, nhóm tách riêng 20% dữ liệu ban đầu làm tập *Test* cố định. Tập *Test* này được giữ nguyên trong toàn bộ quá trình thực nghiệm và chỉ dùng để đánh giá cuối cùng. Phần dữ liệu còn lại được chia thành tập *Train* và *Validation* theo ba tỷ lệ khác nhau gồm 4:1, 7:3 và 6:4. Cách chia này giúp hạn chế việc vừa lựa chọn mô hình vừa đánh giá mô hình trên cùng một tập dữ liệu.

Bên cạnh dữ liệu gốc, nhóm đã sử dụng hai phương pháp giảm chiều là PCA và LDA. PCA giúp giảm số chiều dữ liệu và giữ lại phần lớn phương sai của dữ liệu, trong khi LDA tận dụng thông tin nhãn để tăng khả năng phân tách giữa hai lớp. Kết quả thực nghiệm cho thấy PCA có tác dụng giảm chiều nhưng không phải lúc nào cũng cải thiện hiệu quả phân loại. Ngược lại, LDA thường giúp cải thiện *Recall* đối với lớp 1, đặc biệt khi kết hợp với KNN và SVM.

Các mô hình phân loại được sử dụng trong đề tài gồm K-Nearest Neighbors, Logistic Regression và Support Vector Machine. Ngoài ra, K-Means được sử dụng để quan sát cấu trúc cụm tiềm ẩn của dữ liệu. Các mô hình được đánh giá thông qua các chỉ số *Accuracy*, *Precision*, *Recall*, *F1-score* và *Confusion Matrix*. Trong bài toán y tế này, *Recall* được xem là chỉ số quan trọng nhất vì phản ánh khả năng phát hiện đúng các trường hợp có nguy cơ mắc bệnh. Một mô hình có *Accuracy* cao nhưng *Recall* thấp vẫn có thể không phù hợp nếu bỏ sót nhiều bệnh nhân thuộc lớp dương tính.

Kết quả thực nghiệm cho thấy Logistic Regression là mô hình có hiệu quả ổn định nhất trên tập *Test* cố định. Đặc biệt, Logistic Regression trên dữ liệu gốc với tỷ lệ *Train:Validation* = 6:4 đạt *Accuracy* = 0.9593, *Precision* = 0.6250, *Recall* = 0.9091 và *F1-score* = 0.7407. Ma trận nhầm lẫn của mô hình cho thấy mô hình phát hiện đúng 10 trên 11 mẫu thuộc lớp 1 và chỉ bỏ sót 1 mẫu. Đây là kết quả phù hợp với mục tiêu của bài toán vì mô hình ưu tiên giảm số trường hợp bệnh nhân có nguy cơ bị dự đoán nhầm thành không bệnh.

Đối với K-Means, kết quả phân cụm cho thấy *Silhouette Score* đạt 0.5502, tuy nhiên *Adjusted Rand Index* chỉ đạt 0.0950. Điều này cho thấy các cụm được tạo ra chưa tương ứng rõ ràng với nhãn *Biopsy* thực tế. Vì vậy, K-Means chỉ phù hợp để tham khảo cấu trúc dữ liệu, chưa thể thay thế các mô hình phân loại có giám sát trong bài toán này.

Tuy nhiên, đề tài vẫn còn một số hạn chế. Bộ dữ liệu có kích thước chưa lớn, số lượng mẫu thuộc lớp 1 còn ít và dữ liệu ban đầu tồn tại nhiều giá trị thiếu. Ngoài ra, SMOTE tạo thêm các mẫu tổng hợp nên vẫn có khả năng sinh nhiễu nếu các mẫu thiểu số nằm gần ranh giới giữa hai lớp. Việc đánh giá mô hình cũng mới được thực hiện trên một bộ dữ liệu, chưa kiểm chứng trên các nguồn dữ liệu độc lập khác.

Trong hướng phát triển tiếp theo, có thể mở rộng thực nghiệm với các mô hình khác như Random Forest, XGBoost, LightGBM hoặc các phương pháp lựa chọn đặc trưng. Đồng thời, việc sử dụng thêm dữ liệu thực tế từ nhiều nguồn khác nhau sẽ giúp đánh giá tốt hơn khả năng tổng quát hóa của mô hình. Nhìn chung, kết quả của đề tài cho thấy học máy có thể được sử dụng như một công cụ hỗ trợ tham khảo trong bài toán sàng lọc nguy cơ ung thư cổ tử cung, nhưng không thay thế cho các phương pháp chẩn đoán y tế chuyên môn.

TÀI LIỆU THAM KHẢO

[1] TS. Cao Văn Chung, *Giáo trình môn học Học máy*. Trường đại học Khoa học tự nhiên, Đại học Quốc gia Hà Nội.

[2] Nitesh V. Chawla, Kevin W. Bowyer, Lawrence O. Hall, W. Philip Kegelmeyer. SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, vol. 16, pp. 321-357, 2002.

Bộ dữ liệu của dự án được lấy từ nguồn: [UCI Machine Learning Repository, Cervical Cancer Risk Factors Dataset](#).